

中国市场 Prompt Token 与新闻 收益预测研究报告

从全文表示到目标 token：新浪新闻、巨潮公告与三代中文文本模型的严格样本外研究

本报告系统记录 2010--2026 年中国股票新闻与公告的文本表示、Prompt 机制、目标 token $\rightarrow$ PCA $\rightarrow$ 聚类、收益预测和风险标签研究。研究重点不是寻找单个最高回测值，而是 回答：在相同新闻、相同标签、相同历史窗口和相同降维协议下，目标 token 相对正文 是否提供可重复增量，以及这种增量能否跨模型、Prompt $\rightarrow$ 数据源和年份成立。

研究范围：新浪新闻 796,553 条、巨潮公告 903,665 条及旧新浪严格对齐样本 75,894 条

数据截至：新浪 2026 年 8 月 18 日，巨潮 2026 年 7 月 31 日

事实冻结：2026 年 8 月 26 日

报告性质：研究报告，不构成投资建议或可部署策略声明

目录

中国市场 Prompt Token 与新闻收益预测研究报告

目录
1. 引言：研究问题与主要发现
2. 文献基础与本地研究任务
2.1 工作区原始论文
2.2 从论文骨架到本地研究问题
2.3 本地创新不是机械复刻
3. 数据资产与清洗方法
3.1 数据来源与采集链
3.2 三套不可混用的样本
3.3 年度分布
3.4 文本与标签覆盖
3.5 Mask 与点时约束
4. Embedding 训练与评价流程
4.1 模型与表示
4.2 四方向 Prompt 的 span 定义
4.3 Benchmark 层级
4.4 时间切分与固定参数
4.5 评价指标
4.6 组合与成本
5. 新浪四方向 Prompt 方法验证
5.1 完成范围
5.2 样本外排序
5.3 无聚类线性基线
5.4 成本后的不同答案
5.5 Mask 的配对结果
6. Token 正文与模型几何
6.1 两模型四 Prompt 横向结构
6.2 Qwen 的当前反例
6.3 三模型公平比较的判定门槛
7. 中性语义轴、估值与风险标签
7.1 从方向词扩展到任务词
7.2 收益标签上的单年结构探索
7.3 估值的可检验定义
7.4 波动率和流动性的三个层次
8. 巨潮公告扩展
8.1 全量 pooled 结果
8.2 Qwen 巨潮结果
8.3 横截面和数据源边界

9. 排序、收益与风险解释

9.1 IC 与组合收益不是同一指标

9.2 Token 的价值可能集中在尾部

9.3 成本和卖空限制

9.4 需要补充的风险归因

10. PCA $\cap$ 聚类与模型融合

10.1 为什么主结果只做 PCA 后回归

10.2 聚类原理与本项目实现

10.3 聚类的正面和负面证据

10.4 多因子融合的严格方案

10.5 当前不能写出的结论

11. 综合判断与下一阶段

11.1 当前证据等级

11.2 当前可保留的基线

11.3 下一阶段优先级

11.4 当前资产完整性

12. 研究边界

附录 A：Prompt 与表示合同

附录 B：主要事实来源

附录 C：结果解释的优先级

附录 F：指标和方法速查

参考文献

1. 引言：研究问题与主要发现

新闻全文向量能够压缩公司经营、订单、监管、盈利和风险信息，但全文池化也会把大量与预测任务无关的语句平均进去。Prompt 提供了一个受控的语义查询：同一篇新闻在“分析股票收益”“分析股票亏损”等条件下产生不同的上下文 token。如果目标 token 确实定位了任务相关语义，它应当在严格时间外预测中相对正文产生增量；如果它只反映 词形、长度或模型位置结构，则相似度变化不应被解释为经济理解。

本项目因此沿两条互补路线展开。第一条复现“冻结文本模型加轻量监督预测头”的论文 骨架，建立新闻/公告到未来收益的滚动预测。第二条把研究单位从整篇 pooled embedding 推进到 Prompt 的精确目标 span，比较 RoBERTa、BGE-M3 和 Qwen3-Embedding-8B 的 token 与正文及模型间融合。为了减少公司身份记忆和时间泄漏，新增实验只采用 masked_short，只 mask 公司名、代码、日期和时间。

本文统一术语如下：RankIC 是每天预测排序与实现目标排序的 Spearman 相关再按日平均；严格 6+2+1 表示 6 年训练、2 年验证、1 年测试；PCA 标准化、聚类器和监督模型都只能在当前历史窗口拟合；body_mean 是正文 token 平均，prompt_mean 是 Prompt 槽位平均，目标 token 是排除前缀、句号、separator 和 special token 后的精确目标 span。

研究得到七项主要发现。

- 1. **文本表示中存在跨年的弱收益排序信息。** 新浪 event_return_3d 当前最高跨年 RankIC 为 0.08945，来自 RoBERTa 和 BGE-M3 各自 PCA64 后拼接的 masked“收益”span Ridge；新浪 next_day_return 当前最高为 0.06044，来自 RoBERTa masked 分析股票收益的 prompt_mean Ridge，均为 9/9 个测试年正。
- 2. **Prompt 有效，但不存在一个词在所有口径都最好。** 四方向软聚类最高单配置是 BGE-M3“超额收益”0.04439；跨配置平均由“收益”领先；固定成本后只做多由 BGE-M3 masked“亏损”领先，净年化 8.30%、Sharpe 0.595。
- 3. **Token 的模型结构差异是真实的，但不能直接等同于理解能力。** 在 30,946 个共同股票日上，RoBERTa 四 Prompt token 因子平均相关约 0.653，BGE-M3 约 0.892；正文因子则分别约 0.997 和 0.972。RoBERTa 更 prompt-specific，BGE-M3 更平滑，但哪个更有用仍必须由同样本的样本外增量判定。
- 4. **Qwen token 尚未整体超过正文。** 当前新浪 PCA32 结果中，Qwen masked“收益”token RankIC 为 0.05360，低于 masked article mean 的 0.05680；成本后年化 7.37% 也低于正文 8.57%。局部软聚类更强不足以改写这一总体结论。
- 5. **聚类主要是结构诊断，不是稳定的主预测器。** 四方向硬 KMeans 相对同 PCA Ridge 的平均 RankIC 增量为 -0.00026，仅 6/16 胜。UMAP+HDBSCAN 在一个 BGE-M3 loss 输入上把多空从 15.26bp 提高到 20.35bp，但仍是局部结果。
- 6. **语义轴必须匹配预测标签。** 估值 token 对下一日 PE 历史相对偏离取得 0.0764 RankIC，正文为 0.0651；波动率 token 对下一日绝对实现波动率为 0.0553，与正文 0.0550 几乎相同，对波动率 log 增量则更差。这证明“预测水平”和“预测变化”是不同任务。
- 7. **当前最关键的结论仍未完成验证。** 三模型、四 Prompt token/body 的严格共同样本 PCA32 比较已经设计，但尚未产生完整结果。因此不能写成“Qwen 已经证明兼顾共同语义和细粒度差别”，也不能写成“token 普遍优于正文”。

当前证据支持一个审慎判断：**目标 token 是有条件的文本因子候选，其价值依赖模型、Prompt、标签和监督方法；现阶段最可靠的预测器仍是严格滚动的低维线性模型。**

2. 文献基础与本地研究任务

2.1 工作区原始论文

本项目的文献依据来自工作区内五份原始 PDF，而不是二手摘要。报告仓库不再分发 PDF，但 references/papers_manifest.tsv 保存文件名、页数、书目信息和 SHA256，可逐份检验。

研究	原始文件	核心方法或问题	本项目借鉴
Chen、Kelly、Xiu, <i>Expected Returns and Large Language Models</i>	ExpectedReturns_LLMs.pdf	冻结语言表示、收益监督、16 市场/13 语言、6+2+1 年度滚动	主滚动协议、文本表示与预测头分离、样本外组合
Yang, <i>Investor Sentiment in the Chinese Stock Market</i>	Phd_thesis_Zhijiao_Yang_20219273.pdf	中国市场情绪、横截面检验、成本、卖空限制与百度指数	A 股约束、只做多/理论多空分开、关注度控制
Jiang 等, <i>Deep learning, textual sentiment, and financial market</i>	Deep_learning_textual_sentiment_and_financial_market(1).pdf	以收益标签训练 BERT 情绪，市场级月度预测	收益监督文本表示、非线性和状态异质性
Zhang, 中文 BERT 情绪与股票相关研究	2205.04743v1.pdf	2019--2020 东方财富股吧、BERT 与 MIC	中文语义和非线性相关的探索价值

研究	原始文件	核心方法或问题	本项目借鉴
Wang , <i>Topic Modeling in Finance</i>	134c5fadcdf98503b93ac0ef93b4f0a41b8d.pdf	金融 topic model 与聚类综述	聚类作为结构诊断，避免用 silhouette 代替收益证据

Chen-Kelly-Xiu 的第 20 页明确使用 6 年训练、2 年验证、1 年测试。Jiang 等报告的 2001--2021 年 550 万余条新闻和月度样本外 R^2 8.39% 是市场级月度结果，不能与本项目 个股日频 RankIC 直接比较。不同频率、预测对象和评价指标必须分别说明。

2.2 从论文骨架到本地研究问题

层次	本地问题	主要比较	当前状态
全文基线	新闻/公告全文是否预测未来收益	body_mean/full_mean + Ridge/Huber/MLP	新浪、巨潮均已有效果
Prompt 条件	加入简短任务词是否改变表示	short 与 masked-short-Prompt 间配对	历史四方向完成
Token 定位	精确目标 span 是否优于正文	token 对 body_mean/article_mean	两模型完成，三模型公平比较待完成
几何结构	模型是否把四个词表示为共同语义	cosine-centered cosine-CKA-ARI	部分完成，统一三模型待完成
语义因子	估值、波动率、流动性等是否预测匹配标签	三点轴与风险/估值目标	2026 单折探索完成
模型融合	多 Prompt-多模型是否产生非线性增量	Ridge/ElasticNet/HistGB late fusion	设计和部分旧结果，公平比较待完成

2.3 本地创新不是机械复制

原论文研究完整新闻向量，本项目进一步研究 Prompt 目标 token 的机制。新增设计包括：

- 用 masked_short 删除公司身份、代码、日期和时间，但保留目标语义词；
- 明确区分 Prompt 前缀、目标 span-正文、separator 和 special token ；
- 对 RoBERTa/BGE-M3 使用真正的 body_mean，对 Qwen 使用 article_mean；
- 双向模型的后置 Prompt 可能影响正文表示，因果 Qwen 的后置 Prompt 不反向影响正文；
- 三模型原始维度 768/1024/4096 不直接共享坐标，只统一算法、PCA 维度和历史窗口；
- 从收益扩展到估值、确定性、波动率、冲击、流动性和风险，但要求标签语义匹配。

3. 数据资产与清洗方法

3.1 数据来源与采集链

本项目的两套主文本来自不同信息生成机制。新浪财经是媒体新闻，适合研究新闻叙事、市场 注意力和价格反应；巨潮资讯是上市公司官方公告，适合研究法定披露和事件冲击。东方财富 与雪球只作为公开可见投资者内容的补充，不与主面板混合。

来源	采集方式	当前用途	运行边界
新浪财经	浏览器发现历史 seed ；普通 HTTP depth-3-去重、depth-5 扩展	新闻主面板	联网采集只能本地运行；集群只处理校验后文件
巨潮资讯	官方可见公司页、日期筛选、分页、详情、公开 PDF 下载和文本抽取	公告主面板	不调用隐藏接口，访问控制出现即停止
东方财富	可见要闻、个股页、公告、研报、股吧	情绪/注意力控制	页面间隔至少 3 秒，有界批次
雪球	可见讨论、资讯和公告 feed	情绪/注意力控制	匿名或显式授权 browser state

新浪采用混合方式：浏览器渲染更适合找到动态历史入口和缺失年份，普通 HTTP 更适合批量 正文、原始 HTML 留存和断点恢复。自动 HTTP runner 当前为 20 workers-1 秒批次 pause-30 秒 timeout ，先 depth 3-正文哈希去重，再 depth 5-浏览器 selector 默认 8 pages-3 秒 pause-500ms render wait ；年度补洞默认 4 年任务 x 每年 2 pages-20 workers 是并发 上限而非 20 页/秒。现有普通 DFS 2 页/0.38 秒、浏览器 BFS 4 页/4.90 秒和 DFS 4 页/4.77 秒都只是可运行性微探针，不能外推全量吞吐。

巨潮 2010--2017 采集审计覆盖 816 股票 x 8 年，共 6,528 个股票年且全部完成，原始 完成文件有 554,451 条记录。采集器保存公告索引、详情状态和 PDF ；后续才进行 PDF 文本 抽取、document ID 去重、清洗、分类与收益对齐。最终 903,665 行面板不是原始下载量。

3.2 三套不可混用的样本

样本	期间	行数	股票数	主要用途
新浪全量清洗面板	2010-01-01 至 2026-08-18	796,553	5,466	六中性 Prompt 全量 embedding-后续标签研究

样本	期间	行数	股票数	主要用途
巨潮全量公告面板	2010-01-03 至 2026-07-31	903,665	816	全量公告 pooled/Prompt 估值和风险标签
旧新浪单股对齐面板	2010-01-01 至 2026-08-16	75,894	5,085	四方向 Prompt 的历史 RoBERTa/BGE/Qwen 研究

三套样本的 `row_index` 都在各自面板内唯一，但含义不同。全量新浪和巨潮不能沿用旧 75,894 条面板的行号。三模型四 Prompt 构建器预期的冻结最小交集为新浪 35,576 条、巨潮 254,544 条；这是构建时必须核对的预期值，不是已经完成的最终分析样本。

3.3 年度分布

年份	新浪全量	巨潮全量	旧新浪对齐
2010	17,741	49,255	3,849
2011	20,264	50,982	4,342
2012	14,658	56,101	3,635
2013	5,682	59,963	2,100
2014	1,320	71,882	448
2015	2,120	86,714	686
2016	7,797	90,227	1,463
2017	6,884	87,964	1,459
2018	33,170	39,524	5,171
2019	66,774	38,070	8,097
2020	85,195	39,675	5,369
2021	82,768	41,081	3,478
2022	74,865	42,669	2,969
2023	47,643	45,543	2,104
2024	60,843	39,929	2,744
2025	59,885	42,219	3,524
2026	208,944	21,867	24,456

新浪 2026 年占比明显上升，巨潮 2010--2017 的公告量明显高于 2018 年以后；这类来源和采集结构漂移必须通过年度滚动、逐年指标和固定新闻池诊断，不能把全期随机切分作为主结果。

3.4 文本与标签覆盖

新浪正文清洗字符数中位数为 2,579，90 分位为 9,384，固定最大清洗长度为 12,000 字；796,553 条中有 646,222 条 `next-day` 标签和 643,517 条 `event-3` 标签。巨潮正文字符数中位数 1,765，90 分位 11,737；882,610 条至少有 100 字，895,251 条有 `next-day` 标签，894,851 条有 `event-3` 标签。

巨潮 903,665 条只覆盖当前面板中的 816 只股票。因此“公告条数大”不等于“横截面更广”。新浪覆盖 5,466 只股票，但不同年份和来源的有效覆盖不均。报告中的模型比较必须同时冻结新闻行、股票日、标签可用性和测试年份。

3.5 Mask 与点时约束

新增中性 Prompt 只 mask 公司名、股票代码、日期和时间，不删除盈利、亏损、风险、估值或其他目标词。每行保存稳定 `row_index`、`document_id`、股票代码、发布时间、正文哈希和 Prompt spec 中 mask 的价值首先是控制身份与时间泄漏，不是天然的模式增强。

4. Embedding、训练与评价流程

4.1 模型与表示

模型	模型来源/runner ID	结构	原始维度	输入上限	正文表示	已有代表 RankIC
中文 RoBERTa	hfl/chinese-roberta-wwm-ext	双向 encoder	768	512	body_mean	新浪 0.06044；巨潮 0.01764

模型	模型来源/runner ID	结构	原始维度	输入上限	正文表示	已有代表 RankIC
BGE-M3	BAAI/bge-m3	双向多语言 embedding encoder	1,024	1,000	body_mean	新浪 0.04439；巨潮 0.01415
Qwen3-Embedding-8B	Ollama qwen3-embedding:8b	因果模型	4,096	既有任务合同	article_mean	新浪正文 0.05680；巨潮 0.02732

六个中性 Prompt 固定为：分析股票估值、分析股票确定性、分析股票波动率、分析股票冲击、分析股票流动性、分析股票风险。不添加“请”“综合分析”、高中低或无意义 padding。RoBERTa/BGE-M3 输出同时保存 prompt/title/body/full 的 mean/max。CLS 和 prompt_token_embeddings，因此不是只保存 Prompt token。

表中性能来自不同标签和历史实验，只说明各 runner 已产生有预测力的表示，不能当作严格模型排名。公平比较使用同新闻、同 prompt、同 next-day 标签和各模型训练期 PCA32。双向模型的前置 prompt 可以影响正文 token；Qwen 的 prompt 后置，因果注意力下此前的 article_mean 不受 prompt 反向影响。这一结构差异不能通过统一 PCA 消除。

4.2 四方向 Prompt 的 span 定义

Prompt	目标 span	说明
分析股票盈利	盈利	两个中文 token 的均值
分析股票收益	收益	两个中文 token 的均值
分析股票超额收益	超额收益	公平比较使用完整四字目标 span；部分历史软聚类使用“超额”并单列
分析股票亏损	亏损	两个中文 token 的均值

历史结果保留原有 span 定义，不能事后更改。新的三模型公平比较使用完整目标短语，并在 manifest 中保存 input IDs、tokens、offset mapping、目标 token 索引和 Prompt hash。

4.3 Benchmark 层级

原始论文的主骨架是冻结文本表示、简单监督头、严格滚动和组合检验。本项目按以下顺序区分 benchmark 与扩展，防止把模型复杂度误当作 prompt 信息：

- 非文本控制：过去收益、规模、成交量和历史波动率；
- 传统文本：情绪词典、TF-IDF + Ridge、Word2Vec；
- 整文 Transformer：真正的 body_mean/article_mean；
- prompt pooled：prompt_mean/full_mean；
- 目标 token：精确 span；
- 扩展：mask、硬/软聚类、密度聚类和预测级融合。

当前公平比较的直接 benchmark 固定为同一新闻交集上的训练期 PCA32 + Ridge alpha 100。每个 token/body/聚类配置都与它配对；不做原始 768/1024/4096 维回归，不因最终测试结果切换 PCA 维数。历史 PCA64/raw 结果保留为历史证据，但不混入新主表。

4.4 时间切分与固定参数

新浪主结果使用严格 6+2+1，测试年 2018--2026。巨潮三模型公平比较因历史 embedding 交集限制，基础预测采用 3 年历史加 1 年测试，并在历史窗口内保留 1 年 OOS 供二级融合。语义轴与高频标签的现有探索使用 2018--2023 训练、2024--2025 验证、2026 测试；高频标签 2018--2020 为空，因此实际有效训练年为 2021--2023。

当前公平比较预注册参数为 PCA32、random_state=42、Ridge alpha 100、KMeans k=6、seeds 17/29/42/71/113、soft shrinkage 500、temperature 0.5、UMAP8 和 HDBSCAN min_cluster_size=50，min_samples=10。不做原始维回归，也不根据九年最终结果改参数。

4.5 评价指标

主指标为日均 RankIC、RankIC IR、逐年 RankIC、正 RankIC 年份数、月度正 RankIC 比例和日期区块 bootstrap 区间。辅助指标为同新闻池 Top20% 超额、多空收益、Accuracy、样本外 R²、成本后年化/Sharpe/回撤、因子 Spearman 相关和 Top20% 选股重合率。

Embedding cosine、centered cosine、CKA、ARI 和 silhouette 只描述表示结构，不能选择 收益模型。三模型原始坐标不可直接比较；跨模型只比较标准化几何统计和完全样本外因子。

4.6 组合与成本

四方向历史成本回测固定 $\gamma=0.1$ ，买入和卖出各 5bp 只做多、独立做空和多空必须 分别报告。A 股缺少逐股券源、借券费和召回数据时，任何空头腿都是理论诊断，不能称为 可部署策略。simple_states 返回 ErrorCode=1002 的结果只作为统一平台对照，不替代 正式成本回测。

5. 新浪四方向 Prompt 方法验证

5.1 完成范围

旧新浪 75,894 条母面板上，四个 Prompt、两个模型、short/masked-short 两个变体、九个测试年共 144 个独立软聚类 fold，已完成 144/144。每个 fold 的 PCA 维度、簇数、收益响应、收缩和温度只由验证期选择，测试前再用训练加验证拟合。

5.2 样本外排序

配置	日均 RankIC	正年份	正月份
超额收益 / BGE-M3 / short / RankIC 选择	0.04439	9/9	72/104
收益 / BGE-M3 / short / RankIC 选择	0.04327	9/9	70/104
亏损 / RoBERTa / short / RankIC 选择	0.04317	8/9	65/104
收益 / RoBERTa / short / RankIC 选择	0.04061	9/9	74/104
盈利 / RoBERTa / masked-short / RankIC 选择	0.03920	9/9	70/104




图 1. 四方向 Prompt 软聚类的代表性样本外 RankIC 图中配置不是同一 Prompt 的因果实验。

四个 Prompt 各自八种配置平均后，“收益”RankIC 为 0.03529，“亏损”0.03164，“超额收益”0.03034，“盈利”0.02995。最高单配置与跨配置平均不是同一问题。

5.3 无聚类线性基线

无聚类 Ridge 中，四 Prompt 各八种配置平均 RankIC 为：盈利 0.04480、收益 0.04393、超额收益 0.04385、亏损 0.04281，最大平均差仅 0.00199。单配置最高为 RoBERTa masked “收益”prompt_mean 的 0.06044。四词都含排序信息，但没有证据表明某个词义具有稳定 因果优势。

5.4 成本后的不同答案

目标	最佳配置	净年化	净 Sharpe	最大回撤
只做多	亏损 / BGE-M3 masked / token 软聚类	8.30%	0.595	-22.87%
理论多空	亏损 / RoBERTa short / token 软聚类	4.64%	0.515	-26.45%

所有独立 short_only 配置的成本后 Sharpe 均为负。现有经济结果的主要含义是“低分组 相对更弱”和持仓平滑可能有价值，不能直接解释为可实施卖空收益。

5.5 Mask 的配对结果

16 个严格配对配置中，mask 对只做多净 Sharpe 的平均增量为 +0.069，9/16 胜；对 simple_states IC 的平均增量却为 -0.00480，仅 8/16 胜。mask 可能通过改变持仓尾部 改善经济指标，但没有稳定提高排序。身份控制与预测增强必须分开表述。

6. Token、正文与模型几何

6.1 两模型四 Prompt 横向结构

现有比较使用新浪 30,946 个完全共同股票日上的滚动样本外因子，不是直接把 768 维和 1,024 维原始向量放在同一坐标系计算距离。

指标	RoBERTa	BGE-M3
四 Prompt 正文因子平均 Spearman	0.997	0.972
四 Prompt token 因子平均 Spearman	0.653	0.892
token 与对应正文 Top20 重合	44%	70%
masked 正文平均 RankIC	0.04391	0.03307
masked 目标 span 平均 RankIC	0.04010	0.03154

RoBERTa token 的 Prompt 间差异更大，BGE-M3 token 更接近共同方向。两种解释都可能 成立：前者可能保留有用细粒度，也可能只是词形敏感；后者可能理解共同语义，也可能过度 平滑。只有同新闻、同标签、同 PCA 的 token/body 增量和多 Prompt 融合才能区分。

6.2 Qwen 的当前反例

表示	PCA32 RankIC	成本后年化
masked article mean	0.05680	8.57%
masked“收益”token	0.05360	7.37%

Token 与正文的现有配对结果




图 2. 三模型现有 token/body 结果。RoBERTa/BGE-M3 是四 Prompt 汇总，Qwen 是单一“收益”Prompt，不能当作完全公平的模型排名。

Qwen 当前 token 没有整体超过正文。Qwen 是因果模型且 Prompt 位于正文之后，其 `article_mean` 不受后置 Prompt 反向影响；RoBERTa/BGE-M3 为双向编码器，Prompt 可能改变正文位置的表示。公平比较必须记录这种模型结构差异。

6.3 三模型公平比较的判定门槛

只有同时满足以下条件，才支持“Qwen 兼顾共同语义和细微差别”：RoBERTa centered cosine 显著低于 BGE-M3；BGE-M3 因子相关和选股重合最高；Qwen 几何接近 BGE-M3 但因子重合更低；Qwen 四 token 融合超过最佳单 token 和 Qwen 正文；融合增量至少三分之二测试年为正且区块 bootstrap 区间不跨 0；三模型融合继续超过最佳单模型。

该比较尚未完成。当前只能报告两模型结构事实和 Qwen 单 Prompt token/body 结果。

7. 中性语义轴、估值与风险标签

7.1 从方向词扩展到任务词

研究先构造短/中/长收益、低/中/高估值、确定性、波动率、冲击和流动性三点轴，再形成 `direction` `high/low deviation` `magnitude` `clarity` 和 `neutral distance` 后续又提交六个不含高中低的中性 Prompt，用于判断“高/低”字符是否真正改变表示。

中性 Prompt 不是长度 padding 所有比较保留原始短词，并在同一模型内部使用同一 tokenizer 最大长度、mask 和正文截断合同。不同目标词 token 数不同时，不直接比较原始 token 坐标，而比较训练期标准化后的因子和样本外预测。

7.2 收益标签上的单年结构探索

18 个新 Prompt 的 RoBERTa masked-short token direction 与 body direction 在 2026 严格测试上的平均配对结果如下。

方法	平均 Token-Body RankIC	RankIC 胜出轴数	解释
PCA32 + Ridge	+0.03670	4/6	线性主结果在部分轴显示 token 增量
PCA + hard KMeans + Ridge	+0.03344	5/6	硬簇特征局部有效
soft KMeans	-0.01451	1/6	不稳定
UMAP8 + HDBSCAN + Ridge	-0.00881	3/6	平均无增量

这是 2026 单个测试年，不能替代至少 6/9 年稳定性或日期区块 bootstrap 它支持“新 token 改变了可预测表示”，不支持“所有语义轴 token 普遍优于正文”。

7.3 估值的可检验定义

高估/低估不能由 PE 的绝对值跨股票直接比较。本项目把 PE `PB` `PS` 和 EV/EBITDA 的正值取对数，再减去该股票过去 252 个交易日、至少 60 日的滞后 log 中位数，得到历史相对偏离；预测标签使用下一交易日的该偏离。这控制了不同股票长期估值基准差异。

标签	Token RankIC	Body RankIC	Token-Body	2026 样本
下一日 PE log 偏离	0.0764	0.0651	+0.0113	1,119
下一日 PB log 偏离	-0.0056	0.0197	-0.0254	1,683
下一日 PS log 偏离	0.0106	-0.0069	+0.0175	1,683
下一日 EV/EBITDA log 偏离	0.0107	0.0059	+0.0048	1,274

PE 的点估计较好，但不同估值指标方向不一致，且样本只有约 1,100--1,700 个股票日。不能合并写成“估值 Prompt 已被证明有效”。

7.4 波动率和流动性的三个层次

波动率实验区分：下一交易日实现波动率绝对水平；下一日相对前一日的 $\log_{1p}$ 变化；五日后相对二十日前的波动率跳升。前者容易包含股票固有波动率差异，第二个更接近增量，第三个检验中期风险变化。

标签	Token RankIC	Body RankIC	Token-Body	2026 样本
下一日实现波动率水平	0.0553	0.0550	+0.0003	1,671
下一日实现波动率 log 变化	-0.0236	-0.0085	-0.0151	1,671
五日/二十日波动率跳升	0.0310	0.0253	+0.0057	1,674

流动性使用一分钟买卖价差聚合。下一日价差水平 token/body RankIC 为 0.1881/0.2151；价差 log 变化为 -0.0092/-0.0325。高水平预测强，但可能主要反映稳定的个股流动性差异；变化预测较弱。因此下一步应增加逐股/行业残差化和滞后标签基线。

8. 巨潮公告扩展

8.1 全量 pooled 结果

巨潮全量 pooled embedding 使用 903,665 条公告、RoBERTa/BGE-M3 的 short 和 masked-short，共 72 个一级样本外回归配置，覆盖 2018--2026。

配置	平均 RankIC	正年份
RoBERTa masked full_mean SmallMLP PCA128	0.01764	9/9
RoBERTa short body_mean SmallMLP raw	0.01665	7/9
BGE-M3 masked concat Huber raw	0.01415	9/9
BGE-M3 masked full_mean Huber raw	0.01369	9/9

这些结果说明公告 pooled 表示存在较弱但跨年为正的信号，也说明不同模型的最优预测头不同。它们不是四 Prompt token 的公平比较，不能拿来回答 token 是否优于正文。

8.2 Qwen 巨潮结果

Qwen 巨潮 3+1+1 辅助滚动的 masked-short PCA32 Huber SGD RankIC 为 0.02732，5/5 年方向一致；严格 2026 点估计为 0.02247，但 95% 区间 [-0.00181, 0.05117] 跨 0，且 plain 的点估计略高于 masked-short 当前只能称为弱而可重复的线性信号。

8.3 横截面和数据源边界

巨潮全量有 90 万余条公告，却只覆盖面板中的 816 只股票；新浪股票更广但来源、长度和年份结构不同。两数据源的模型结果不能按原始 RankIC 直接归因于“新闻优于公告”或反之。公平比较需要同一股票日、同一目标、相同训练历史和相同可评分横截面。

9. 排序、收益与风险解释

9.1 IC 与组合收益不是同一指标

RankIC 使用每天整个可评分横截面的排序；Top20% 组合只看尾部，并受持仓平滑、换手、成本和收益偏度影响。因此“超额收益”有最高软聚类 RankIC，而“亏损”有最高成本后只做多，并不矛盾。报告必须同时给出排序和经济结果。

9.2 Token 的价值可能集中在尾部

旧比较中，RoBERTa token 与正文 Top20 重合只有约 44%，BGE-M3 约 70%。RoBERTa 盈利、收益、亏损 token 相对对应正文的多空收益增量曾为正，而超额收益是反例。这提示 token 可能主要改变尾部选股，而不是整体 RankIC；但该机制需要在新公平样本上复核。

9.3 成本和卖空限制

四方向最佳只做多年化 8.30%、Sharpe 0.595，最大回撤仍为 -22.87%。最佳理论多空 年化 4.64%、Sharpe 0.515，且独立空头配置成本后均未形成正 Sharpe。没有券源与借券费时，应把低分端理解为风险规避或降低权重候选，而不是直接做空策略。

9.4 需要补充的风险归因

下一步的经济评价应在同一股票日加入市场和行业调整收益、规模、动量、短期反转、beta、历史波动率、流动性、换手和新闻数量。只有“传统因子”“新闻因子”“传统加新闻”在完全同折下比较，才能判断文本是否提供独立增量。

10. PCA、聚类与模型融合

10.1 为什么主结果只做 PCA 后回归

三模型原始维度差异大，且高维样本量比例不同。主口径固定训练期 randomized PCA32 后 StandardScaler 和 Ridge alpha 100，不再运行原始维回归。这使跨模型统一成为“同算法、同维数、同历史窗口和同参数”，而不是错误地共享同一个 PCA 基底。

10.2 聚类原理与本项目实现

聚类不是独立重复一份无监督图，而是在训练期 PCA 表示上检验离散或非线性语义状态能否对未来收益产生监督增量。四类方法使用相同 fold，所有变换只在训练期拟合。

方法	原理	当前实现
硬 MiniBatchKMeans	最小化样本到最近质心的平方距离，得到离散状态	PCA32 后 k=6，one-hot/质心距离与 PCA 特征进入 Ridge；历史 sweep k=2/4/6/8/12
软 KMeans	用距离 softmax 替代硬边界，以 membership 加权簇收益	temperature=0.5；训练期簇收益向全局均值 shrinkage=500；测试冻结
UMAP+HDBSCAN	UMAP 保留局部近邻，HDBSCAN 按密度发现非球形簇并允许噪声	PCA -> UMAP8 (cosine, neighbors 30, min_dist 0.1) -> HDBSCAN (50/10) -> Ridge
GMM	PCA 空间的多高斯混合，以后验概率表示重叠簇	Qwen 结构复核使用 k=3/5/8；不作为当前主收益选择器

软 KMeans 的训练期簇收益为 $\mu_k = (\sum(y_i \text{ in } k) + 500 * global_mean) / (n_k + 500)$ ，样本分数为各簇 μ_k 按距离 membership 的加权和。验证和测试收益不参与 μ_k 。UMAP/HDBSCAN 的验证测试标签通过训练期 transform/approximate prediction 获得，不能在全样本 UMAP 图上回填收益。

ARI 检查不同 seed/年份的分簇一致性，silhouette 检查簇内/簇间几何，noise share 检查 HDBSCAN 是否退化；它们只用于描述结构，不能用于选择收益模型。有效性只看与同一 PCA+Ridge 配对的 OOS RankIC 组合和跨年稳定性。

10.3 聚类的正面和负面证据

硬 KMeans 在四方向 16 个严格配对中平均降低 RankIC 0.00026，仅 6/16 胜。BGE-M3 收益 token 的簇收益排序比 RoBERTa 清晰，说明其表示更容易形成连续分层；但软聚类最高 0.04439 仍低于无聚类 Ridge 0.06044。

UMAP+HDBSCAN 在 BGE-M3 masked loss 的同一输入上把多头从 1.50bp 提高到 6.17bp，多空从 15.26bp 提高到 20.35bp，8/9 年方向为正。它是值得保留的局部稳健性结果，但没有跨 Prompt 稳定胜出，也没有超过已有最佳软聚类配置。2026 单折的六语义轴中，PCA+Ridge 和硬 KMeans 的平均 token-body delta 为 +0.03670/+0.03344，软 KMeans 和 UMAP+HDBSCAN 为 -0.01451/-0.00881，进一步说明聚类增量依赖任务，不能预设为正。

10.4 多因子融合的方案

公平比较先生成 24 个完全样本外基础因子：3 模型 × 4 Prompt × token/body。融合分为单模型四 token、单 Prompt 三模型、12 token、12 body 和全部 24 因子。输入先逐日横截面标准化，再比较等权、Ridge、ElasticNet 和 HistGradientBoosting 二级权重。只能使用历史 OOS/验证数据，测试年冻结。

10.5 当前不能写出的结论

- 不能因 RoBERTa Prompt 间距离大就写“RoBERTa 不理解语义”；
- 不能因 BGE-M3 token 相关高就写“BGE-M3 理解更准确”；
- 不能因 Qwen 局部软聚类更强就写“Qwen token 已超过正文”；
- 不能把新浪 35,576 和巨潮 254,544 的预期交集当作已完成样本；
- 不能用一次 2026 单折的估值/风险结果替代 6+2+1 跨年验证。

11. 综合判断与下一阶段

11.1 当前证据等级

结论	证据	当前判断
文本 embedding 含收益排序信息	新浪多个配置 9/9 年正；巨潮 pooled 多个配置跨年正	支持弱文本因子
简短 Prompt 改变可预测表示	四方向结果、mask 配对、不同 span 排名	支持，但非稳定增强
Token 普遍优于正文	两模型平均 RankIC token 略低；Qwen token 也低于正文	不支持
RoBERTa 与 BGE 的 Prompt 几何不同	因子相关 0.653 对 0.892，正文相关均很高	支持结构差异，不等于理解优劣
聚类稳定提高收益预测	硬聚类平均负增量；UMAP 只有局部正例	当前不支持
估值 Prompt 预测高估/低估	PE 有正点估计，PB/PS/EV 分化，单年小样本	探索性证据
波动率 Prompt 预测未来风险	水平略正，log 增量更弱	仅支持水平信息，增量未验证
Qwen 兼顾共同语义和细粒度并可融合	严格三模型四 Prompt 结果未完成	尚未验证

11.2 当前可保留的基线

1. 新浪 next-day : RoBERTa masked 分析股票收益 prompt_mean PCA/Ridge 主基线。
2. 新浪 event-3 : RoBERTa/BGE-M3 masked“收益”span 各自 PCA 后拼接 Ridge
3. 方向 Prompt 机制：四词目标 span token 与真正 body_mean 的严格配对。
4. 巨潮公告：现有 pooled 72 配置只作为公告全文基线；三模型 token 比较单独报告。
5. 非线性：只在 PCA32 因子或完全 OOS 预测层运行 HistGradientBoosting，不再扩展高维树网格。

11.3 下一阶段优先级

1. 完成新浪和巨潮三模型四 Prompt 共同样本构建，先核对实际交集、年份、标签和选择偏差。
2. 运行 PCA32 token/body Ridge，并生成逐年 RankIC 配对 bootstrap 因子相关和 Top20 重合。
3. 在基础 OOS 因子完成后做等权、Ridge ElasticNet 和 HistGradientBoosting late fusion
4. 将估值标签扩展为行业相对和横截面分位；将波动率/价差同时报告水平、变化和滞后基线增量。
5. 把文本因子与量价、beta 行业、规模、动量、反转和流动性因子放入完全共同股票日比较。
6. 只有达到至少 6/9 年方向一致且区块 bootstrap 区间不跨 0，才升级为主结论。

11.4 当前资产完整性

六个中性 masked-short Prompt 的 embedding 完整性如下。RoBERTa 新浪完整；巨潮缺一个分片；BGE-M3 剩余任务已主动取消并保留完成产物，因此只能在已完成分片交集探索。




图 3. 中性六 Prompt embedding 分片完成度。未完成 BGE-M3 不能冒充全量结果。

12. 研究边界

- 新浪与巨潮虽然都覆盖 2010--2026，但年度分布、股票覆盖、文本类型和标签可用率不同。
- 旧新浪 75,894 条、全量新浪 796,553 条和巨潮 903,665 条的 `row_index` 不可混用。
- 2026 新浪数据量异常高，任何随机切分都会受到来源与时间漂移影响。
- 巨潮当前全量面板只覆盖 816 只股票，不代表无偏全 A 股公告历史。
- RoBERTa/BGE-M3 是双向编码器，Qwen 是因果模型；Prompt 位置影响机制不同。
- Qwen 当前只完成单一“收益”Prompt 的 token/body 对照，不能代表四 Prompt 平均。
- 估值、波动率和价差结果目前主要来自 2026 单折和约 1,100--1,700 个股票日。
- 聚类超参数、PCA 和 scaler 必须在训练期拟合；ARI/silhouette 不能选择收益模型。
- 成本回测未包含容量、冲击、涨跌停、融资、借券费和券源召回。
- `simple_states ErrorCode=1002` 的结果不是正式成本后策略证据。
- 本报告描述预测关系和表示结构，不提供因果解释，也不构成投资建议。

附录 A Prompt 与表示合同

实验族	Prompt	变体	目标 span	正文表示
四方向	分析股票盈利	masked-short	盈利	body_mean/article_mean
四方向	分析股票收益	masked-short	收益	body_mean/article_mean
四方向	分析股票超额收益	masked-short	超额收益	body_mean/article_mean
四方向	分析股票亏损	masked-short	亏损	body_mean/article_mean
中性估值	分析股票估值	masked-short	估值	body_mean
中性确定性	分析股票确定性	masked-short	确定性	body_mean
中性波动率	分析股票波动率	masked-short	波动率	body_mean
中性冲击	分析股票冲击	masked-short	冲击	body_mean
中性流动性	分析股票流动性	masked-short	流动性	body_mean
中性风险	分析股票风险	masked-short	风险	body_mean

附录 B 主要事实来源

事实	可追溯产物
新浪两种采集流程、默认并发和微探针	scripts/run_sina_auto_pipeline.py、scripts/select_sina_historical_seeds_browser.py、data/interim/sina_*probe.json
巨潮 2010--2017 股票年和原始记录	reports/cninfo_historical_collection_audit.json、reports/cninfo_historical_cleaning_audit.json
东方财富/雪球可见页面边界和批次	scripts/collect_browser_visible.py、scripts/run_100_stock_collection.py
模型 ID 维度、最大长度和表示合同	references/data_sources_and_models.md 和 embedding manifest/preflight
全量面板行数、日期、股票数、标签覆盖	facts.json；scripts/audit_research_handoff.py；相应 Parquet schema
四方向 Prompt 掩码成本和聚类结果	工作区 REPORT_ALL_RESULTS.md，SHA256 23ade165...e4ff
估值、波动率、价差配对结果	reports/aligned_extended_regression/token_body_selected.csv
新语义轴聚类配对	reports/aligned_factor_clusters/token_minus_body_delta.csv
中性 embedding 完成度	docs/status_snapshot_2026-08-26.json 和 embedding shard COMPLETED
论文书目信息和原文校验	references/papers_manifest.tsv、references/paper_to_experiment_map.md

附录 C 结果解释的优先级

- 冻结输入、严格滚动、跨年完成且有明确标签的样本外结果；
- 同新闻、同标签、同历史窗口的配对结果；
- 单年严格测试和小样本语义匹配探索；
- embedding 几何、聚类质量和可视化；
- 尚未运行完成的设计、预期交集和研究假设。

低优先级证据不能覆盖高优先级证据。尤其不能用 cosine 解释替代 token/body 的样本外 预测，也不能用单个最优组合覆盖所有其他 Prompt 和模型的负结果。

附录 F 指标和方法速查

名称	定义	本报告解释
日均 RankIC	每日预测与目标横截面的 Spearman 相关再平均	首要排序指标，不年化

名称	定义	本报告解释
RankIC IR	日度 RankIC 均值除以标准差	衡量稳定性，需同时报告日期数
正年份数	测试年份中 RankIC 大于 0 的年份数	方向稳定性，不代表统计显著
OOS R ²	相对历史均值预测误差的改善	可为负而 RankIC 为正
Top20 重合	token 与正文最高 20% 股票集合的交集比例	描述尾部选择相似度
centered cosine	去除训练期 Prompt 均值后的余弦	减少全局 Prompt 偏置
线性 CKA	两组表示样本几何的一致性	可跨不同原始维度描述，不共享坐标
PCA32 Ridge	训练期 PCA32 标准化、固定 alpha 100	三模型公平比较主基线
hard KMeans	PCA 后簇 one-hot 与连续特征进入 Ridge	聚类增强，必须配对同 PCA Ridge
soft KMeans	距离软分配加训练期簇收益收缩	连续分层，不使用测试收益定义簇分数
UMAP+HDBSCAN	训练期 PCA/UMAP/密度簇后进入 Ridge	稳健性复核，不以 silhouette 选收益模型
GMM	PCA 空间高斯混合的后验软 membership	Qwen 结构复核，当前不作为主收益选择器
年化/Sharpe	扣固定交易成本后的组合收益统计	仍未包含容量、涨跌停和借贷约束

参考文献

1. Chen, Y., Kelly, B., and Xiu, D. *Expected Returns and Large Language Models*. 2024.
2. Yang, Z. *Investor Sentiment in the Chinese Stock Market*. PhD thesis, 2023.
3. Jiang, F., Liu, Y., Meng, L., and Zhang, H. *Deep learning, textual sentiment, and financial market*. 2024.
4. Zhang, C. *Deep learning based Chinese text sentiment mining and stock market correlation research*. 2022.
5. Wang, X. *Topic Modeling in Finance: A Review of Methods, Applications, and Challenges*. 2026.