

中国市场 Prompt Token 与新闻收益预测研究报告

从全文表示到目标 token：新浪新闻、巨潮公告与三代中文文本模型的严格样本外研究

本报告系统记录 2010--2026 年中国股票新闻与公告的文本表示、Prompt 机制、目标 token、PCA、聚类、收益预测和风险标签研究。研究重点不是寻找单个最高回测值，而是 回答：在相同新闻、相同标签、相同历史窗口和相同降维协议下，目标 token 相对正文 是否提供可重复增量，以及这种增量能否跨模型、Prompt、数据源和年份成立。

研究范围：新浪新闻 796,553 条、巨潮公告 903,665 条及旧新浪严格对齐样本 75,894 条

数据截至：新浪 2026 年 8 月 18 日，巨潮 2026 年 7 月 31 日

事实冻结：2026 年 8 月 27 日

报告性质：研究报告，不构成投资建议或可部署策略声明

目录

中国市场 Prompt Token 与新闻收益预测研究报告

目录
1. 引言：研究问题与主要发现
2. 文献基础与本地研究任务
2.1 工作区原始论文
2.2 从论文骨架到本地研究问题
2.3 本地创新不是机械复刻
3. 数据资产与清洗方法
3.1 数据来源与采集链
3.1.1 巨潮目前爬取范围：技术范围与已完成范围不是一回事
3.1.2 新浪为什么必须在本本地，以及实际爬取逻辑
3.2 三套不可混用的样本
3.3 年度分布
3.4 文本与标签覆盖
3.5 从原始文本到可交易日期：清洗与对齐合同
新浪：源文章与股票-文章行分开计数
巨潮：903,816 中间档不等于 903,665 冻结面板
公告日、首个可交易日与标签
3.6 Mask 与点时约束
4. Embedding、训练与评价流程
4.1 模型、输入布局与表示
4.1.1 Prompt 与正文如何隔断
4.1.2 prompt_mean、目标 token、body_mean 和 full_mean
4.1.3 Embedding 用时、并行资源和估算边界
4.2 两模型四方向 Prompt 的同口径收益统计
4.3 四方向 Prompt 的 span 定义
4.4 Benchmark 层级
4.5 时间切分与固定参数
4.6 评价指标
4.7 组合与成本
5. 新浪四方向 Prompt 方法验证
5.1 完成范围
5.2 样本外排序
5.3 无聚类线性基线
5.4 成本后的不同答案
5.5 Gamma 敏感性：拆分 Top20% 与慢调仓
5.6 Mask 的配对结果
5.6.1 线性 RankIC：同模型、同表示的直接配对
5.6.2 成本后组合：排序改善不等于同样大小的净收益改善
5.6.3 如何解释 Mask

5.7 Prompt 的已确认作用与因果边界	
5.7.1 已确认：不同目标词产生不同表示和股票排序	
5.7.2 尚未确认：加入 Prompt 相对无 Prompt 的因果增量	
6. Prompt Mean、Token、全文与模型几何	
6.1 RoBERTa/BGE-M3：Prompt Mean 与方向 Token	
6.1.1 共同股票日上的 full_mean 与 Token	
6.2 Qwen：同一 PCA32 下的三种表示	
6.3 三模型四 Prompt Token 的公平比较	
7. 中性语义轴、估值与风险标签	
7.1 从方向词扩展到任务词	
7.2 新 Prompt 在同一收益标签上的公平比较	
7.3 估值的可检验定义	
7.4 波动率和流动性的三个层次	
8. 巨潮公告扩展	
8.1 合并面板 pooled 结果	
8.2 Qwen 巨潮结果	
8.3 横截面和数据源边界	
9. 排序、收益与风险解释	
9.1 IC 与组合收益不是同一指标	
9.2 Token 的价值可能集中在尾部	
9.3 成本和卖空限制	
9.4 需要补充的风险归因	
10. PCA、聚类与模型融合	
10.1 为什么主结果只做 PCA 后回归	
10.2 聚类原理与本项目实现	
10.3 聚类的正面和负面证据	
硬 KMeans：结构变化没有转化为整体收益增量	
软 KMeans：当前优势主要在持仓平滑和尾部	
UMAP+HDBSCAN：局部正例，但未计成本	
10.4 多因子融合的严格方案	
10.5 当前不能写出的结论	
11. 综合判断与下一阶段	
11.1 当前证据等级	
11.2 当前可保留的基线	
11.3 下一阶段优先级	
11.4 主线一：证明不同 Prompt 真的产生不同因子	
11.5 三模型相关性应该如何理解	
11.6 主线二：Regime、全股票与宏观新闻扩展	
11.7 当前资产完整性	
12. 研究边界	
附录 A：Prompt 与表示合同	
附录 B：主要事实来源	

附录 C：结果解释的优先级

附录 F：指标和方法速查

参考文献

1. 引言：研究问题与主要发现

新闻全文向量能够压缩公司经营、订单、监管、盈利和风险信息，但全文池化也会把大量与预测任务无关的语句平均进去。Prompt 提供了一个受控的语义查询：同一篇新闻在“分析股票收益”“分析股票亏损”等条件下产生不同的上下文 token。如果目标 token 确实定位了任务相关语义，它应当在严格时间外预测中相对正文产生增量；如果它只反映词形、长度或模型位置结构，则相似度变化不应被解释为经济理解。

本项目因此沿两条互补路线展开。第一条复现“冻结文本模型加轻量监督预测头”的论文骨架，建立新闻/公告到未来收益的滚动预测。第二条把研究单位从整篇 pooled embedding 推进到 Prompt 的精确目标 span，比较 RoBERTa、BGE-M3 和 Qwen3-Embedding-8B 的 token、正文及模型间融合。为了减少公司身份记忆和时间泄漏，新增实验只采用 masked_short，只 mask 公司名、代码、日期和时间。

本文统一术语如下：RankIC 是每天预测排序与实现目标排序的 Spearman 相关再按日平均；严格 6+2+1 表示 6 年训练、2 年验证、1 年测试；PCA、标准化、聚类器和监督模型都只能在当前历史窗口拟合；body_mean 是正文 token 平均，prompt_mean 是 Prompt 槽位平均，目标 token 是排除前缀、句号、separator 和 special token 后的精确目标 span。

研究得到七项主要发现。

- 1. 文本表示中存在跨年的弱收益排序信息。** 新浪 event_return_3d 当前最高跨年 RankIC 为 0.08945，来自 RoBERTa 和 BGE-M3 各自 PCA64 后拼接的 masked “收益” span Ridge；新浪 next_day_return 当前最高为 0.06044，来自 RoBERTa masked 分析股票收益的 prompt_mean Ridge，均为 9/9 个测试年正。
- 2. Prompt token 能区分任务视角，mask 在配对线性结果中多数有效，但不存在一个词在所有口径都最好。** 无聚类 Ridge 的 prompt_mean 在 mask 后 8/8 配对改善，平均 RankIC 增量 +0.00324；目标 span 为 7/8 改善、平均 +0.00297。四方向软聚类最高单配置是 BGE-M3 “超额收益” 0.04439；跨配置平均由“收益”领先；固定成本后只做多由 BGE-M3 masked “亏损”领先，净 3.63 bp/交易日、年化 8.30%、Sharpe 0.595。尚缺位置匹配的无 Prompt 反事实，不能把它表述为加入 Prompt 的因果增量。
- 3. Token 的模型结构差异是真实的，但不能直接等同于理解能力。** 新公平 token 因子中，新浪 RoBERTa/BGE-M3/Qwen 的四 Prompt 平均相关为 0.678/0.877/0.663，巨潮为 0.692/0.891/0.657。BGE-M3 最平滑，Qwen 在保留 Prompt 差异的同时取得最高 RankIC；RoBERTa 也有较低相关，但差异没有转化为同等预测力。
- 4. Qwen token 尚未整体超过正文。** 当前新浪 PCA32 结果中，Qwen masked “收益” token RankIC 为 0.05360，低于 masked article mean 的 0.05680；成本后年化 7.37% 也低于正文 8.57%。局部软聚类更强不足以改写这一总体结论。
- 5. 聚类主要是结构诊断，不是稳定的主预测器。** 四方向硬 KMeans 相对同 PCA Ridge 的平均 RankIC 增量为 -0.00026，仅 6/16 胜；Top20% 多头也由线性的 4.77 降至 4.28 净 bp/信号日。UMAP+HDBSCAN 在一个 BGE-M3 loss 输入上把无成本多空从 14.96 提高到 19.72 bp/信号日，但每腿平均不足 5 只，仍是局部结果。软聚类固定因子在 gamma=1 时毛收益仍为 4.73 bp/日，但成本后为 -0.55 bp，说明慢调仓是经济结果的关键组成部分。
- 6. 新 Prompt 在同一收益标签上呈现任务相关差异，但证据仍是单年。** 2026 同新闻、同三日收益标签下，期限收益轴 token 在 PCA Ridge、硬 KMeans、软 KMeans 和 UMAP+HDBSCAN 四种方法中都高于波动率轴，四方法平均 RankIC 为 0.03987 对 0.00967；但线性 PCA Ridge 仅为 0.043105 对 0.042975。匹配标签实验中，估值 token 对下一日 PE 相对偏离为 0.0764，波动率 token 对下一日实现波动率为 0.0553。
- 7. 三模型四 Prompt token 比较已完成，但树聚合没有稳定增量。** 巨潮 Qwen 最佳单 Prompt/验证期选择树的平均 RankIC 为 0.05274/0.05275，新浪 2026 为 0.05649/0.05459；Qwen 在两个数据源上都领先。BGE-M3 的四 Prompt 因子相关最高，但 RoBERTa/BGE-M3 的树模型均弱于最佳单 Prompt。该结果支持 Prompt token 因子存在结构差异，不支持“固定树模型优于简单组合”，也尚未完成四 Prompt token/body 配对。

当前证据支持一个审慎判断：目标 token 是有条件的文本因子候选，其价值依赖模型、Prompt、标签和监督方法；现阶段最可靠的预测器仍是严格滚动的低维线性模型。

2. 文献基础与本地研究任务

2.1 工作区原始论文

本项目的文献依据来自工作区内五份原始 PDF，而不是二手摘要。报告仓库不再分发 PDF，但 references/papers_manifest.tsv 保存文件名、页数、书目信息和 SHA256，可逐份核验。

研究	原始文件	核心方法或问题	本项目借鉴
Chen、Kelly、Xiu, Expected Returns and Large Language Models	ExpectedReturns_LLMs.pdf	冻结语言表示、收益监督、16 市场/13 语言、6+2+1 年度滚动	主滚动协议、文本表示与预测头分离、样本外组合
Yang, Investor Sentiment in the Chinese Stock Market	Phd_thesis_Zhijiao_Yang_20219273_.pdf	中国市场情绪、横截面检验、成本、卖空限制与百度指数	A 股约束、只做多/理论多空分开、关注度控制
Jiang 等, Deep learning, textual sentiment, and financial market	Deep_learning_textual_sentiment_and_financial_mark (1).pdf	以收益标签训练 BERT 情绪，市场级月度预测	收益监督文本表示、非线性和状态异质性
Zhang, 中文 BERT 情绪与股票相关研究	2205.04743v1.pdf	2019--2020 东方财富股吧、BERT 与 MIC	中文语义和非线性相关的探索价值
Wang, Topic Modeling in Finance	134c5fadcdf98503b93ac0ef93b4f0a41b8d.pdf	金融 topic model 与聚类综述	聚类作为结构诊断，避免用 silhouette 代替收益证据

Chen、Kelly、Xiu 的第 20 页明确使用 6 年训练、2 年验证、1 年测试。Jiang 等报告的 2001--2021 年 550 万余条新闻和月度样本外 R^2 8.39% 是市场级月度结果，不能与本项目 个股日频 RankIC 直接比较。不同频率、预测对象和评价指标必须分别说明。

2.2 从论文骨架到本地研究问题

层次	本地问题	主要比较	当前状态
全文基线	新闻/公告全文是否预测未来收益	body_mean/full_mean + Ridge/Huber/MLP	新浪、巨潮已有 pooled 基线；新公平样本的 body 配对尚未完成
Prompt 条件	加入简短任务词是否改变表示	short 与 masked-short、Prompt 间配对	历史四方向配对完成；无 Prompt 反事实仍待完成
Token 定位	精确目标 span 是否优于正文	token 对 body_mean/article_mean	三模型四 Prompt token 因子已完成；Qwen 仅“收益”有 article 对照，两 encoder 历史宽表示为 full_mean，公平 body 对照待完成
几何结构	模型是否把四个词表示为共同语义	cross-Prompt 因子相关、cosine、CKA、ARI	新公平结果已完成逐日四因子相关；统一 centered cosine/CKA/ARI 尚待完成
语义因子	估值、波动率、流动性等是否预测匹配标签	三点轴与风险/估值目标	RoBERTa 2026 单折探索完成；六条中性 Prompt 尚无共同收益回归
Prompt 因子聚合	同一模型的多 Prompt 是否产生非线性增量	四 token 等权、XGBoost/LightGBM/CatBoost	三模型分别完成；树模型不混合模型，跨模型与 token/body late fusion 待完成

2.3 本地创新不是机械复刻

原论文研究完整新闻向量，本项目进一步研究 Prompt 目标 token 的机制。新增设计包括：

- 用 masked_short 删除公司身份、代码、日期和时间，但保留目标语义词；
- 明确区分 Prompt 前缀、目标 span、正文、separator 和 special token；
- 对 RoBERTa/BGE-M3 使用真正的 body_mean，对 Qwen 使用 article_mean；
- 双向模型的后置 Prompt 可能影响正文表示，因果 Qwen 的后置 Prompt 不反向影响正文；
- 三模型原始维度 768/1024/4096 不直接共享坐标，只统一算法、PCA 维数和历史窗口；
- 从收益扩展到估值、确定性、波动率、冲击、流动性和风险，但要求标签语义匹配。

3. 数据资产与清洗方法

3.1 数据来源与采集链

本项目的两套主文来自不同信息生成机制。新浪财经是媒体新闻，适合研究新闻叙事、市场注意力和价格反应；巨潮资讯是上市公司官方公告，适合研究法定披露和事件冲击。东方财富与雪球只作为公开可见投资者内容的补充，不与主面板混合。

来源	采集方式	当前用途	运行边界
新浪财经	浏览器发现历史 seed；普通 HTTP depth-3、去重、depth-5 扩展	新闻主面板	联网采集只能本地运行；集群只处理校验后文件
巨潮资讯	官方可见公司页、日期筛选、分页、详情、公开 PDF 下载和文本抽取	公告主面板	不调用隐藏接口，访问控制出现即停止
东方财富	可见要闻、个股页、公告、研报、股吧	情绪/注意力控制	页面间隔至少 3 秒，有界批次
雪球	可见讨论、资讯和公告 feed	情绪/注意力控制	匿名或显式授权 browser state

新浪采用混合方式：浏览器渲染更适合找到动态历史入口和缺失年份，普通 HTTP 更适合批量 正文、原始 HTML 留存和断点恢复。自动 HTTP runner 当前为 20 workers、1 秒批次 pause、30 秒 timeout，先 depth 3、正文哈希去重，再 depth 5。浏览器 selector 默认 8 pages、3 秒 pause、500ms render wait；年度补洞默认 4 年任务 x 每年 2 pages。20 workers 是并发上限而非 20 页/秒。现有普通 DFS 2 页/0.38 秒、浏览器 BFS 4 页/4.90 秒和 DFS 4 页/4.77 秒都只是可运行性微探针，不能外推全量吞吐。

巨潮整体覆盖 2010--2026 和同一批 816 只研究股票，但筛选口径在 2018 年发生变化：2010--2017 抓取这 816 只股票的全部公告，2018--2026 使用这 816 只股票的重点公告。2010--2017 采集审计覆盖 816 股票 x 8 年，共 6,528 个股票年且全部完成，原始完成文件有 554,451 条记录。采集器保存公告索引、详情状态和 PDF；后续才进行 PDF 文本抽取、document ID 去重、清洗、分类与收益对齐。最终 903,665 行是两个口径合并后的 清洗面板，不是全时期全部公告，也不是原始下载量。

3.1.1 巨潮目前爬取范围：技术范围与已完成范围不是一回事

巨潮采集器的单股票参数是 CODE:ORG_ID:NAME。只要股票在巨潮公开公司披露页可以解析出 stockCode 和 orgId，就可以按日期筛选、遍历分页、打开详情页并下载公开 PDF；因此 技术上可爬取的是可被公开页面识别的上市公司公告，而不是固定的 816 只股票。当前完整 历史审计没有宣称覆盖全 A 股，实际采用的是研究股票池与收益面板的交集： data/stock_universe_paper_1000.csv 的 1,000 个候选中，最终有 816 只进入完整审计。

范围口径	股票数量	说明
研究候选池	1,000	论文/收益研究预先固定的候选股票，不等于巨潮全市场
当前完整历史审计	816	候选池与清洗公告/收益标签可对齐的交集；两个时期股票范围相同
交易所构成	沪市 64、深市 752	当前面板没有纳入北交所股票
代码前缀	000/001/002/300、600/601/603/688	具体数量冻结在 facts.json，不是按前缀推断公告存在
历史股票年	816 x 8 = 6,528	2010--2017，6,528/6,528 股票年完成

当前 816 只股票的 2010--2017 全部公告由 run_cninfo_historical_local.sh 分年执行，每个 股票单独输出 JSON、详情状态和 PDF；完成文件原始记录 554,451 条，清洗合并后为 553,088 行。2018--2026 使用同一批 816 只股票的重点公告，清洗面板为 350,577 行。两段合计 903,665 行，不能理解为“本次爬虫一次下载了 903,665 份 PDF”，也不能称为 2010--2026 全时期全部公告。清洗阶段统一进行 PDF 文本抽取、公告 URL/document ID 去重、正文长度过滤、分类和收益对齐；如要扩展到全 A 股，需要先 建立新的股票目录、为每只股票解析 orgId、做小批量可见页探针，再按股票年审计缺失，不能 直接把 --expected-stocks 从 816 改成全市场。

单股票 collector 支持 --index-only 只保存可见索引，也支持 --focus-only 仅保留 业绩、分红、回购、重组、合同、诉讼、监管等研究标题。正式全量口径使用索引、详情和公开 PDF，失败、空 PDF、访问控制和导航超时都写入状态，不把失败记录填成空正文；因此可以区分“没有公告”“页面访问失败”和“PDF 无可抽取文本”。

3.1.2 新浪为什么必须在本 地，以及实际爬取逻辑

“新浪只能本地抓取”是本项目的数据源访问和可复现约束，不是 embedding 或 CPU 任务限制。新浪页面的历史入口、编码和可见内容需要浏览器/HTTP 的真实访问上下文；在集群节点分布式 发起联网请求会带来访问控制、限速、IP/会话不一致和无法复现的问题。因此规定：本地机器 完成种子发现、页面请求和原始文件落盘，集群只接收本地生成并校验过的 HTML/JSONL/state/manifest/checksum，进行清洗、embedding 和回归；不在 Slurm CPU/GPU 节点联网抓取。

新浪的完整逻辑是“本地浏览器发现 + 本地普通 HTTP 扩展 + 本地去重/清洗”：

- 1. **发现种子**：浏览器打开公开可见的历史新闻入口、频道和年份页面，记录 URL、父链接、 年份、股票匹配、正文长度和正文 hash。按照股票、年份、季度、频道路径和标题差异做 farthest-first，避免所有 seed 集中在热门股票或单一年份。
- 2. **第一轮扩展**：从人工/浏览器 seed 运行普通 HTTP depth-3 图搜索，使用有界 ThreadPoolExecutor，保存 raw HTML 和逐行 records；robots/访问异常/超时进入 state，不无限重试。
- 3. **解析与初筛**：按 HTTP/meta charset 识别 GBK/GB18030 等历史编码，解析标题、时间、正文和链接；正文保留 120--12,000 字符，股票关联同时使用页面股票链接、显式代码和公司 名称词典。
- 4. **全局去重**：先按规范化 URL 去重，再按正文 SHA256 去重；不能只按标题去重。当前 runner 还排除明确识别为 2000 年的异常记录。
- 5. **第二轮扩展**：把去重后的有效文章 URL 写成新的 roots，再运行 depth-5 HTTP 扩展， 解决文章互相链接但第一轮尚未到达的问题；第二轮同样保存 state、manifest 和失败状态。
- 6. **年度补洞**：普通 HTTP 找不到动态入口或年份断档时，使用浏览器年度 runner 按年独立 队列补洞；每年单独输出，最后合并前按 URL/body hash 去重并检查年份分布。

7. **交接与集群处理**：本地跑完后复制 raw/records/state/manifest/checksum 到 Lustre，先验 hash 和行数，再由集群做文本清洗、mask、tokenizer preflight、embedding 和滚动回归。

推荐的本地命令是 scripts/run_sina_auto_pipeline.py：默认 20 个 HTTP workers、批次间隔 1 秒、单请求 30 秒、depth-3 后 depth-5；浏览器 selector 默认 8 个页面、3 秒间隔和 500ms 渲染等待。20 workers 是并发上限，不是 20 页/秒；正式吞吐必须以带 summary 的本地长跑测量，不能用 2--4 页微探针外推全量容量。每次修改 parser 或参数后，都应使用新 output-dir/manifest 版本，避免不同规则的 records 混在同一 frontier state 中。

3.2 三套不可混用的样本

样本	期间	行数	股票数	主要用途
新浪全量清洗面板	2010-01-01 至 2026-08-18	796,553	5,466	六中性 Prompt 全量 embedding、后续标签研究
巨潮分段口径合并面板	2010-01-03 至 2026-07-31	903,665	816	2010--2017 全部公告 + 2018--2026 重点公告；pooled/Prompt、估值和风险标签
旧新浪单股对齐面板	2010-01-01 至 2026-08-16	75,894	5,085	四方向 Prompt 的历史 RoBERTa/BGE/Qwen 研究

三套样本的 row_index 都在各自面板内唯一，但含义不同。全量新浪和巨潮不能沿用旧 75,894 条面板的行号。三模型四 Prompt 已完成的冻结 embedding 交集为新浪 35,576 条、巨潮 254,544 条；二级树模型使用一级 PCA32-Ridge 完全样本外预测形成的股票日，而不是直接把这俩新闻行数当作回归样本量。

3.3 年度分布

年份	新浪全量	巨潮合并面板	旧新浪对齐
2010	17,741	49,255	3,849
2011	20,264	50,982	4,342
2012	14,658	56,101	3,635
2013	5,682	59,963	2,100
2014	1,320	71,882	448
2015	2,120	86,714	686
2016	7,797	90,227	1,463
2017	6,884	87,964	1,459
2018	33,170	39,524	5,171
2019	66,774	38,070	8,097
2020	85,195	39,675	5,369
2021	82,768	41,081	3,478
2022	74,865	42,669	2,969
2023	47,643	45,543	2,104
2024	60,843	39,929	2,744
2025	59,885	42,219	3,524
2026	208,944	21,867	24,456

新浪 2026 年占比明显上升。巨潮 2010--2017 数量明显高于 2018 年以后，不只是自然年度差异，还因为前段为全部公告、后段为重点公告。这个 2018 年筛选断点必须通过年度滚动、逐年指标、公告类型占比和固定公告池诊断，不能把全期随机切分作为主结果，也不能把前后数量变化解释为公司披露行为本身。

3.4 文本与标签覆盖

新浪正文清洗字符数中位数为 2,579，90 分位为 9,384，固定最大清洗长度为 12,000 字；796,553 条中有 646,222 条 next-day 标签和 643,517 条 event-3 标签。巨潮正文字符数中位数 1,765，90 分位 11,737；882,610 条至少有 100 字，895,251 条有 next-day 标签，894,851 条有 event-3 标签。

巨潮合并面板 903,665 条只覆盖同一批 816 只股票，且 2018 年前后公告筛选口径不同。因此“公告条数大”不等于“横截面更广”，也不等于每一年都覆盖全部公告。新浪覆盖 5,466 只股票，但不同年份和来源的有效覆盖不均。报告中的模型比较必须同时冻结新闻行、股票日、标签可用性和测试年份。

3.5 从原始文本到可交易日期：清洗与对齐合同

新浪：源文章与股票-文章行分开计数

新浪原始清洗输入有 714,555 行，其中 714,549 行可进入解析。经过无效时间、日期范围和 URL 日期冲突、乱码、指数/行情/专题页、短正文等规则后，接受 **167,713 篇源文章**。股票识别只接受清洗后标题/正文中的明确六位代码或无歧义公司名，不把页面自带股票链接单独当作真值。一篇新闻可以明确涉及多只股票，按股票展开后得到 **796,553 个研究行**、5,466 只股票。因此 167,713 与 796,553 描述不同层级，不是两版互相冲突的样本数。

网页清洗删除现代页面头、显示发布时间外壳、导航、分享、编辑/推广尾注和异常替换字符；正文至少 120 字。去重顺序是 `source_article_id+stock_id`、`url+stock_id`、`stock_id+cleaned_text_hash`，既删除同一股票的重复文章，也保留同一新闻对不同股票的独立研究行。最终重新生成唯一 `document_id`、稳定 `row_index` 和正文 `hash`。

巨潮：903,816 中间档不等于 903,665 冻结面板

巨潮先记录详情/PDF 成功或失败状态，再抽取文本并清除页码、HTML、URL、PDF/浏览器样板、替换字符和异常空白。通用合并清洗档从 913,014 行按 `stock_id+text_hash` 删除 9,198 行后得到 **903,816 行**；相同文本属于不同股票时仍保留。正式研究和中性 embedding 没有直接采用该档，而是冻结两个已审计时期包：2010--2017 全部公告 553,088 行，加 2018--2026 重点公告 350,577 行，合计 **903,665 行**。

151 行差异目前只能确认是版本/选择合同不同，尚未完成逐行原因审计。严谨做法是把 903,665 固定为当前论文面板，保留两套 manifest 并单独做 row-level diff；在审计完成前，不能把 903,816 替换进 embedding，也不能猜测差异来自“重复”或“短文本”。

公告日、首个可交易日与标签

所有证券代码补齐为六位，首位为 5/6 的证券映射 .SH，其余映射 .SZ。新浪时间先按 UTC 解析，再转为 Asia/Shanghai 本地时间；巨潮优先使用 `published_at`，缺失时使用 `announcement_date`。大量历史公告只有日期级 00:00+08:00，因此主面板采用统一的保守规则，而不声称知道盘中精确发布时间：

```
text event_center_date = 公告自然日当日或之后的首个交易所交易日 entry_date = 严格晚于公告自然日的首个交易日
next_day_return = entry_date 对应的日收益 O2O = entry_date 开盘至下一交易日开盘
```

周末和节假日按真实交易日历顺延。该主合同不使用“收盘前公告当天可交易”的 cutoff；它牺牲一部分时间精度来避免日期级公告被当成盘前已知信息。`event_return_3d` 复合 center-1、center、center+1，可能包含公告前交易日，只能解释为事件标签，不能作为公告后可部署的三日收益。O2O 只有两个开盘价都存在且通过 IPO/可交易检查才保留。

估值使用 backward as-of，只允许最近的 `available_at <= published_at` 记录进入新闻行；未来估值或当前最新估值不能回填历史。

下一日波动率、价差和流动性先在 ticker 内显式 `shift(-1)`，再按股票/日期合并。模型侧的 scaler、PCA、聚类器和回归器仍只在当前历史 fold 拟合，从数据点时和模型训练两层控制前视。

3.6 Mask 与点时约束

short 保留清洗正文中的身份和时间字段；masked_short 在相同短 Prompt 下只处理下表 四类字段。这里的“mask”是一个完整文本处理 treatment，不等于模型内部 attention mask。

文本元素	是否 mask	理由
公司全称、简称和可识别公司身份	是	降低模型依赖公司记忆或固定身份效应
股票代码	是	避免代码成为公司 ID 的直接代理
日期与具体时间	是	降低时间记忆、格式捷径和显式日期泄漏
Prompt 目标词，如盈利、收益、亏损、风险、估值	否	目标 span 是研究对象，删除后任务定义失效
新闻中的经营、财务、事件和方向内容	否	保留真正需要编码的经济信息

概念上，某公司（000001）于某日宣布盈利改善 只把公司、代码和日期替换为统一占位，“盈利改善”继续可见。新增中性 Prompt 每行保存稳定 row_index、document_id、股票代码、发布时间、正文哈希和 Prompt spec；tokenizer preflight 另存 prompt IDs、目标 span 和截断合同。历史四方向配对使用已完成的 short/masked-short 产物，行和标签相同，但 masking 会改变输入 token 上下文，这正是配对 treatment 的组成部分。因此它识别的是“移除四类身份/时间字段的 总效果”，不能进一步归因到公司名、代码或日期中的某一个字段。

mask 的第一职责是控制身份与时间捷径，不是天然的模型增强。若未来要检验严格点时性，还应逐条验证正文中公告日期、报告期和相对时间表达是否属于事件内容；这些经济日期不能在 没有规则审计的情况下全部删除。

4. Embedding、训练与评价流程

4.1 模型、输入布局与表示

模型	模型来源/runner ID	结构	原始维度	本轮输入上限	正文表示
中文 RoBERTa	hfl/chinese-roberta-wwm-ext	双向 encoder	768	512	body_mean
BGE-M3	BAAI/bge-m3	双向多语言 embedding encoder	1,024	1,000	body_mean
Qwen3-Embedding-8B	Ollama/GGUF qwen3-embedding:8b	因果模型	4,096	500	article_mean

六个中性 Prompt 固定为：分析股票估值、分析股票确定性、分析股票波动率、分析股票冲击、分析股票流动性、分析股票风险。不添加“请”“综合分析”、高中低 或无意义 padding。RoBERTa/BGE-M3 输出同时保存 prompt/title/body/full 的 mean/max、CLS 和 prompt_token_embeddings，因此不是只保存 Prompt token。

4.1.1 Prompt 与正文如何隔断

实现不是三模型共用一个字符串模板，而是两种不同的序列合同：

- RoBERTa / BGE-M3：[BOS] → Prompt → 标题 → 正文 → [EOS]；
- Qwen3-Embedding-8B：标题正文 → \n\n → Prompt → [EOS]。

项目	RoBERTa / BGE-M3	Qwen3-Embedding-8B
Prompt 位置	正文前	正文后
模型可见的 Prompt/正文 separator	没有额外 separator token	双换行 \n\n；已审计 GGUF 中为 1 token
标题/正文 separator	没有额外 token，只保存内部段标签	标题和正文直接拼成 article
段标签	segment_id=0/1/2 只用于输出池化，不作为 token_type_ids 传给模型	由位置和双换行确定边界
注意力方向	双向：Prompt、标题和可见正文互相上上下文	因果：Prompt 可看此前正文，正文不能看后置 Prompt
超长处理	从序列尾部截断；优先保留 Prompt/标题，正文尾部及可能的 EOS 被截去	先为 separator、Prompt、EOS 预留预算，再截断 article

因此 RoBERTa/BGE-M3 的“隔断”是池化边界而非模型注意力边界：模型仍把相邻 Prompt、标题和正文作为一个连续序列处理。Qwen 的双换行是模型可见边界，同时由于因果注意力， article_mean 的每个 article token 都位于 Prompt 之前，不会被后置 Prompt 反向改变。

相同中文也不是相同 token。以收益 Prompt 为例，实际 tokenizer 审计为：RoBERTa 的分析股票收益 是 分/析/股/票/收/益 六个 token；BGE-M3 是 __/分析/股票/收益 四个 token；Qwen 输入为 分析股票收益。， 是 分析/股票/收益/。 四个 token。跨模型比较的是相同算法和样本外统计，不是相同 token 数量或原始 embedding 坐标。

4.1.2 prompt_mean、目标 token、body_mean 和 full_mean

令最后一层上下文 hidden state 为 h_i ，各表示只改变取哪些位置平均：

表示	计算位置	是否包含 Prompt	解释
prompt_token_embeddings	保存每个 Prompt 位置的 h_i ，形状为 $N \times P \times D$	是	这是张量，不是单一向量
目标 token/span	$\text{mean}(h_i, i \in \text{目标词位置})$	只含目标词	例如只取“收益”；多 token 目标取 span 均值
prompt_mean	$\text{mean}(h_i, i \in \text{全部 Prompt 位置})$	是	同时混合“分析”“股票”和目标词；Qwen 历史输入还含句号
body_mean	$\text{mean}(h_i, i \in \text{正文段})$	不直接池化 Prompt	RoBERTa/BGE-M3 中正文 hidden state 仍受前置 Prompt 双向影响
article_mean	$\text{mean}(h_i, i \in \text{Qwen 标题+正文})$	否	因果结构下不受后置 Prompt 影响
full_mean	$\text{mean}(h_i, i \in \text{Prompt+标题+正文})$	是	不能命名为 body_mean
title_body_mean	$\text{mean}(h_i, i \in \text{标题+正文})$	不直接池化 Prompt	双向模型中仍是 Prompt-conditioned 正文表示

这里的 $N \times P \times D$ 是数组形状，不是把三个数相乘后得到一个指标：

- N ：该文件中的新闻/公告条数，一行对应一篇输入；
- P ：该 Prompt 保存的 token 位置数，不同 tokenizer 和 Prompt 可以不同；
- D ：模型 hidden size，RoBERTa/BGE-M3/Qwen 分别为 768/1,024/4,096。

例如 RoBERTa 的分析股票收益 有六个目标 Prompt token，所以一个含 N 条新闻的文件是 $N \times 6 \times 768$ ；第 n 条新闻、第 p 个 Prompt token 对应一个 768 维上下文文化向量。BGE-M3 的同一句审计为四个 Prompt token，对应 $N \times 4 \times 1,024$ 。选取“收益”目标位置并对多 token span 求均值后，数组由 $N \times P \times D$ 变成 $N \times D$ ；prompt_mean 则对全部 P 个 Prompt 位置平均，同样得到 $N \times D$ ，随后才进入训练期 PCA 和回归。

所有 mean 都排除 BOS/EOS、padding 和不可见位置。目标 token_embedding 也不是词典中的 静态 token embedding，而是**整篇输入前向计算后的最后一层上下文文化 hidden state**。Qwen 的 prompt_mean 对历史四词任务平均全部 Prompt token，包括末尾句号；“收益”token 只选 收益，排除“分析”“股票”和句号。

4.1.3 Embedding 用时、并行资源和估算边界

六个中性 Prompt 的正式 CPU 任务采用 256 shards、最大并行 256、每 task 8 CPU/ 32 GB、24 小时时限。每个 task 只加载一次模型，再连续编码 shard 内六个 Prompt；RoBERTa 为 batch 8、最大 512 token，BGE-M3 为 batch 4、最大 1,000 token。下表来自 Slurm 已完成 array element 的 ElapsedRaw，排队时间未混入计算时间。

数据/模型	完成分片	单分片中位数	P90	最大值	已观察 array 活跃墙钟
新浪 RoBERTa	256/256	46分50秒	3时04分36秒	3时32分12秒	4时28分17秒，完整
巨潮 RoBERTa	255/256	1时11分10秒	2时01分47秒	4时33分41秒	9时16分57秒，基础 array 缺 shard-225
新浪 BGE-M3	189/256	5时15分51秒	9时07分35秒	15时19分15秒	15时49分45秒，仅部分任务
巨潮 BGE-M3	78/256	4时36分44秒	4时54分07秒	6时42分05秒	8时28分01秒，仅部分任务

RoBERTa 新浪整组是完整生产实测。巨潮基础 array 有一个失败分片，必须把 shard-225 补跑 产物纳入 manifest 后再称 256/256 完整。BGE-M3 两组分别取消 67 和 178 个未完成任务，已保留 588,049 和 221,551 行产物；表中的墙钟只是已运行任务窗口，**不是全量完成时间**。

容量估算应先确定有效并发，再按 wave 计算：

text 计算墙钟 $\approx \text{ceil}(256 / \text{有效并发数}) \times \text{代表性单分片用时} \times (1 + \text{I/O/验收余量})$ 总周转时间 = Slurm 排队等待 + 计算墙钟

健康 CPU 节点和 256 个并发槽位都可用时，采用 P90 并加至少 20% I/O/验收余量，BGE-M3 单个全量 array 的条件预算约为新浪 **10--16 小时**、巨潮 **5--7 小时**；有效并发只有 64 时约需四个 wave。这个预算不是 SLA，因为节点速度差异和共享 Lustre I/O 已经使新浪 BGE 单 shard 从 1.45 小时分散到 15.3 小时。

Qwen 的完整参考 job 3651805 使用一张 RTX 4090, 57,741 行 pooled embedding 用时 18,715 秒, 即 5时11分55秒、约 3.085 行/秒。按同吞吐, **单次 pooled pass** 线性外推 为新浪 71.7 小时、巨潮 81.4 小时。该 job 只输出单个 4,096 维 pooled 向量, 不是六 Prompt 的 token/full/body 完整合同; 输入长度、GGUF runner、token 落盘、缓存和 GPU 数量 都会改变速度, 故不得把单次外推乘六后写成正式工期。完整审计见 [references/embedding_runtime_audit_20260826.md](#)

4.2 两模型四方向 Prompt 的同口径收益统计

上一版在模型介绍表中混放了新浪/巨潮、next-day/event/O2O 和不同表示, 不能用于判断 prompt 收益能力。下面改用现有最完整的严格可比表: 旧新浪共同面板、2018--2026 的 6+2+1 滚动、next_day_return、masked_short、各 prompt 历史 direction span、无聚类线性 Ridge。late_fusion 是历史文件名, 表中四行均为独立 prompt 预测。

Prompt / 历史 direction span	RoBERTa RankIC	BGE-M3 RankIC	RoBERTa - BGE
盈利	0.05430	0.03812	+0.01618
收益	0.05394	0.03556	+0.01838
超额收益 / 实际取 “超额”	0.05644	0.03720	+0.01923
亏损	0.05479	0.03431	+0.02048

四个 prompt 在两个模型中均为正, 且该口径下 RoBERTa 全部高于 BGE-M3。RoBERTa 内部由 “超额收益” 最高, BGE-M3 内部由 “盈利” 最高; “收益” 并非每个模型的最高点。因此这张表支持方向词 token 含有收益排序信息和模型差异, 不支持某个方向词普遍最优。四词平均 RankIC 为 RoBERTa **0.05486**、BGE-M3 **0.03630**。这里的 RankIC 是每个 测试日横截面 Spearman IC 的平均, 不是回归系数; 表中没有把九年收益组合、成本或 Sharpe 混入同一个数。来源为 [reports/prompt_cluster_token_comparison.json](#) 中 method_family=linear_ridge, variant=masked_short 的八个配置。

4.3 四方向 Prompt 的 span 定义

Prompt	目标 span	说明
分析股票盈利	盈利	取语义字符 span; 实际 token 数由各模型 tokenizer 决定
分析股票收益	收益	取语义字符 span; 不包含 “分析股票”
分析股票超额收益	超额	本报告历史 word-span 结果只取 “超额” ; 不是完整目标短语
分析股票亏损	亏损	取语义字符 span; 不包含 “分析股票”

历史结果必须保留原有 span 定义, 不能事后把 “超额” 改写成 “超额收益”。新的三模型公平 比较才使用完整目标短语, 并在 manifest 中保存 input IDs、tokens、offset mapping、目标 token 索引和 Prompt hash。

4.4 Benchmark 层级

原始论文的主骨架是冻结文本表示、简单监督头、严格滚动和组合检验。本项目按以下顺序 区分 benchmark 与扩展, 防止把模型复杂度误当作 prompt 信息:

- 非文本控制: 过去收益、规模、成交量和历史波动率;
- 传统文本: 情绪词典、TF-IDF + Ridge、Word2Vec;
- 整文 Transformer: 真正的 body_mean/article_mean;
- prompt pooled: prompt_mean/full_mean;
- 目标 token: 精确 span;
- 扩展: mask、硬/软聚类、密度聚类和预测级融合。

当前公平比较的直接 benchmark 固定为同一新闻交集上的训练期 PCA32 + Ridge alpha 100。每个 token/body/聚类配置都与它配对; 不做原始 768/1024/4096 维回归, 不因最终测试 结果切换 PCA 维数。历史 PCA64/raw 结果保留为历史证据, 但不混入新主表。

4.5 时间切分与固定参数

新浪一级因子使用严格 6+2+1, 测试年 2018--2026; 二级 Prompt 聚合因子只有在已有一级 OOS 历史足够时才测试, 因此实际二级测试年为 2026。巨潮按用户指定的 3+1 外层口径报告 2024--2026; 每个外层测试年内部使用 2 年一级 OOS 因子拟合、1 年验证、1 年测试, 不能用一级样本内预测补齐更早年份。语义轴与高频标签的现有探索使用 2018--2023 训练、2024--2025 验证、2026 测试; 高频 标签 2018--2020 为空, 因此实际有效训练年为 2021--2023。

当前公平比较预注册参数为 PCA32、random_state=42、Ridge alpha 100、KMeans k=6、seeds 17/29/42/71/113、soft shrinkage 500、temperature 0.5、UMAP8 和 HDBSCAN min_cluster_size=50, min_samples=10。不做原始维回归，也不根据九年最终结果改参数。

4.6 评价指标

主指标为日均 RankIC、RankIC IR、逐年 RankIC、正 RankIC 年份数、月度正 RankIC 比例 和日期区块 bootstrap 区间。辅助指标为同新闻池 Top20% 超额、多空收益、Accuracy、样本外 R²、成本后年化/Sharpe/回撤、因子 Spearman 相关和 Top20% 选股重合率。

Embedding cosine、centered cosine、CKA、ARI 和 silhouette 只描述表示结构，不能选择 收益模型。三模型原始坐标不可直接比较；跨模型只比较标准化几何统计和完全样本外因子。

4.7 组合与成本

四方向历史成本回溯固定 gamma=0.1，买入和卖出各 5bp。只做多、独立做空和多空必须 分别报告。A 股缺少逐股券源、借券费和召回数据时，任何空头腿都是理论诊断，不能称为 可部署策略。simple_states 返回 ErrorCode=1002 的结果只作为统一平台对照，不替代 正式成本回溯。

组合评价不能只看 RankIC。本报告同时冻结：日均毛收益、日均交易成本、日均净收益、实际持仓数、新信号数、换手、净 Sharpe 和最大回撤。bp/交易日 使用逐日收益直接取均值，不是由年化收益倒推。不同执行器的成本和持仓规则不得混表：旧线性/硬聚类 Top20% 模拟按 年重置、买入 5bp/卖出 10bp；软聚类正式组合使用 gamma=0.1、无信号继续持仓；密度聚类 股票日模拟未扣成本。

5. 新浪四方向 Prompt 方法验证

5.1 完成范围

旧新浪 75,894 条母面板上，四个 Prompt、两个模型、short/masked-short 两个变体、九个测试年共 144 个独立软聚类 fold，已完成 144/144。每个 fold 的 PCA 维度、簇数、收益响应、收缩和温度只由验证期选择，测试前再用训练加验证拟合。

5.2 样本外排序

配置	日均 RankIC	正年份	正月份
超额收益 / BGE-M3 / short / RankIC 选择	0.04439	9/9	72/104
收益 / BGE-M3 / short / RankIC 选择	0.04327	9/9	70/104
亏损 / RoBERTa / short / RankIC 选择	0.04317	8/9	65/104
收益 / RoBERTa / short / RankIC 选择	0.04061	9/9	74/104
盈利 / RoBERTa / masked-short / RankIC 选择	0.03920	9/9	70/104




图 1. 四方向 Prompt 软聚类的代表性样本外 RankIC。图中配置不是同一 Prompt 的因果实验。

四个 Prompt 各自八种配置平均后，“收益”RankIC 为 0.03529，“亏损”0.03164，“超额收益”0.03034，“盈利”0.02995。最高单配置与跨配置平均不是同一问题。

5.3 无聚类线性基线

无聚类 Ridge 中，每个 Prompt 的八种配置来自两个模型、short/masked-short 和 prompt_mean/目标 span。下表同时给出配置平均和各 Prompt 自身最佳点，避免只展示一个 winner。

Prompt	八配置平均 RankIC	最佳配置	最佳 RankIC	正年份
盈利	0.04480	RoBERTa masked prompt_mean	0.05791	9/9
收益	0.04393	RoBERTa masked prompt_mean	0.06044	9/9
超额收益	0.04385	RoBERTa short “超额” span	0.05851	9/9
亏损	0.04281	RoBERTa masked prompt_mean	0.05957	9/9

四 Prompt 平均差仅 0.00199，而最佳单配置的词和变体并不相同。它说明四词都含收益排序 信息，Prompt 选择与模型/表示存在交互；不能由“收益”的 0.06044 推导出“收益这个词在 所有模型和组合指标都最好”。更详细的 mask 配对见 5.6，Prompt 本身的因果边界见 5.7。

5.4 成本后的不同答案

下表逐 Prompt 选择现有固定 $\gamma=0.1$ 、5bp 成本回测中净 Sharpe 最高的只做多配置。它是事后描述性 leader，不是测试期可重新选择的单一部署策略。

Prompt	配置	毛 bp/日	成本 bp/日	净 bp/日	名义持仓	有效持仓	当日 Q5	换手/日	净 Sharpe
盈利	RoBERTa masked / 多空验证目标	3.65	0.56	3.10	101.8	14.66	1.10	5.58%	0.468
收益	BGE-M3 masked / 多空验证目标	4.01	0.55	3.46	89.9	13.93	1.10	5.53%	0.537
超额收益	RoBERTa masked / 多空验证目标	4.13	0.56	3.57	103.6	15.11	1.10	5.61%	0.526
亏损	BGE-M3 masked / RankIC 验证目标	4.18	0.55	3.63	97.4	13.90	1.10	5.51%	0.595

Top20% 仍然只作用于**当日可用股票池**：每天平均 6.14 只有效候选，对应当日 Q5 平均 1.10 只。股票数量增加发生在执行层，而不是软聚类层。 $\gamma=0.1$ 使用 $\text{目标仓位}_t=0.9\times\text{目标仓位}_{t-1}+0.1\times\text{当日Q5仓位}$ ，且无信号时继续持仓；旧股票权重逐日 衰减而不是清零。容差为 $1e-14$ 时，许多极小权重仍被计入 n_{long} ，所以名义持仓累积到 90--104 只；按 $(\sum |w|)^2/\sum (w^2)$ 计算的权重有效持仓只有 13.9--15.1 只。

因此软聚类结果同时反映 token 排序、收益簇映射和 EWCT 慢调仓，不能把 3.10--3.63 净 bp 全部归因于聚类。若要检验聚类本身，应让线性和软聚类共用同一 γ 与清仓规则。

所有独立 short_only 配置的成本后 Sharpe 均为负。现有经济结果的主要含义是“低分组 相对更弱”和持仓平滑可能有价值，不能直接解释为可实施卖空收益。

5.5 Gamma 敏感性：拆分 Top20% 与慢调仓

固定上表四个 Prompt leader 的因子和预测，不重新选模型，只改变 γ 。下表是四个 配置的平均值；当日 Q5 始终为 1.10 只，因此股票数量变化完全来自执行层。

γ	毛 bp/日	成本 bp/日	净 bp/日	换手/日	名义持仓	有效持仓	净 Sharpe
0.1	3.99	0.56	3.44	5.55%	98.2	14.40	0.532
0.2	4.60	1.08	3.53	10.79%	69.2	9.59	0.519
0.5	5.08	2.64	2.44	26.39%	37.9	4.37	0.303
1.0	4.73	5.28	-0.55	52.80%	1.74	1.74	-0.044

四 Prompt 固定 leader 的执行层 gamma 敏感性




图 2. 同一四个软聚类因子只改变执行层 gamma；当日 Q5 数量不变，持仓与成本显著变化。

gamma=1 时毛收益仍有 4.73 bp/日，甚至高于 gamma=0.1，说明软聚类分数的当日排序 不是完全无效；但 5.28 bp/日成本将平均净收益压到 -0.55 bp，四 Prompt 只有盈利和亏损 仍为正。gamma=0.2 的平均净 bp 略高于 0.1，而 0.1 的净 Sharpe 更高。由于这些是全测试期 敏感性，不能事后把 0.2 升级为正式参数；主表继续固定 0.1。

所以当前最严格的表述是：软聚类有毛收益排序信息，EWCT 通过降低换手把它转化为成本后 收益。还缺少同一 gamma 下线性 Ridge 与软聚类的配对组合，聚类算法的独立净增量尚未识别。

5.6 Mask 的配对结果

5.6.1 线性 RankIC：同模型、同表示的直接配对

以下每一行固定新浪旧共同面板、next_day_return、6+2+1、2018--2026 测试年和无聚类 Ridge，只改变 short → masked_short。prompt_mean 是整个短 Prompt 槽位平均；历史 direction span 只平均“盈利/收益/超额/亏损”，不包含“分析股票”、句号和 special token。

Prompt / 模型	Prompt mean short	masked	增量	历史 span short	masked	增量
盈利 / RoBERTa	0.05510	0.05791	+0.00281	0.05323	0.05430	+0.00107
收益 / RoBERTa	0.05427	0.06044	+0.00617	0.04935	0.05394	+0.00459
超额收益 / RoBERTa	0.05016	0.05132	+0.00116	0.05851	0.05644	-0.00207
亏损 / RoBERTa	0.05112	0.05957	+0.00845	0.04730	0.05479	+0.00749
盈利 / BGE-M3	0.03072	0.03392	+0.00320	0.03514	0.03812	+0.00298
收益 / BGE-M3	0.03173	0.03313	+0.00140	0.03301	0.03556	+0.00255
超额收益 / BGE-M3	0.03205	0.03304	+0.00099	0.03207	0.03720	+0.00513
亏损 / BGE-M3	0.03071	0.03241	+0.00171	0.03227	0.03431	+0.00204

prompt_mean 为 8/8 改善，平均/中位 RankIC 增量分别为 **+0.00324/+0.00226**；历史 span 为 7/8 改善，平均/中位分别为 **+0.00297/+0.00276**。RoBERTa “超额收益”的“超额”span 是唯一线性反例，说明 mask 的平均收益不是机械地发生在每个 token 上。




图 3. 同一模型和表示下 masked-short 减 short 的 RankIC；mask 对 Prompt mean 更一致，对历史 direction span 存在一个明确反例。

5.6.2 成本后组合：排序改善不等于同样大小的净收益改善

只看 RankIC 会漏掉 mask 对组合尾部的影响。四个历史 direction span、两个模型的线性/硬聚类 Top20% 模拟合计 16 个配对中，masked-short - short 的净收益平均为 **+3.21 bp/信号日**，13/16 胜；持仓数固定为 2.80，只是选中的股票发生变化。软聚类正式持仓的对应增量较小，为 **+0.43 bp/交易日**、9/16 胜，净 Sharpe 平均增加 0.069。

Prompt	软聚类 mask 净 bp/日增量	线性 Ridge mask 净 bp/信号日增量	硬 KMeans mask 净 bp/信号日增量
盈利	+0.41	+4.35	+4.53
收益	+0.59	+4.73	+6.26
超额收益	+0.27	+0.03	-0.22
亏损	+0.44	+4.04	+1.95

这给出四类中的具体正反例：收益、亏损和盈利在两种执行器中大多受益；超额收益在线性 Top20% 仅 +0.03 bp，硬聚类反而 -0.22 bp。另一方面，simple_states IC 的 mask 平均增量为 -0.00480，仅 8/16 胜。结论应写成“mask 明显改变股票选择，并在现有组合协议中平均改善净 bp”，不能写成“mask 必然提高表示质量”。它的第一职责仍是移除身份和日期泄漏。

5.6.3 如何解释 Mask

线性 RankIC、集中 Top20% 和 EWCT 软组合的胜率不同，原因是它们测量不同环节：RankIC 使用每天整个可用横截面；集中 Top20% 只测尾部且换手很高；EWCT 叠加簇收益映射、旧仓衰减和低换手。可审计的共同结论只有两点：mask 确实改变了预测排序；在当前样本和多数配对中，移除身份/时间字段有益。它尚不能证明模型完全不使用公司身份，也不能证明任何 mask 规则都会改善未来数据。

5.7 Prompt 的已确认作用与因果边界

5.7.1 已确认：不同目标词产生不同表示和股票排序

四 Prompt 无聚类八配置平均 RankIC 从 0.04281 到 0.04480，跨度很小；最佳单配置却从 0.05791 到 0.06044，且“超额收益”的最佳点来自未 mask 的“超额”span。这说明 Prompt 效应不是一个统一加成，而是词 × 模型 × 表示 × mask 的交互。因子几何也支持这种差异：在 30,946 个共同股票日上，RoBERTa 四 Prompt token 因子平均 Spearman 为 0.653，明显低于 full_mean 的 0.997；BGE-M3 为 0.892，对应 full_mean 0.972。RoBERTa 更词敏感，BGE-M3 更平滑，但这本身不能判定哪一种语义理解更正确。

历史同滚动汇总还给出一个重要反例：prompt_mean 并没有自动胜过更宽的池化。

表示	历史平均 RankIC (约)	可回答的问题
full_mean	0.04395	Prompt 与正文共同池化后的整体信号
prompt_mean	0.04360	整个 Prompt 槽位是否集中收益信息
收益方向 span	0.04414	目标方向词的局部表示

表示	历史平均 RankIC (约)	可回答的问题
“股票” span	0.04649	任务对象 token 的局部表示

这些平均数来自历史多配置汇总，不是本节 16 个 mask 配对的等权重算，也不用于模型选择。它们说明“加入 Prompt 后应提取哪个位置”仍是经验问题，不能把 Prompt 槽位平均当作默认答案。

组合尾部也不是 RankIC 的简单复制：四个 Prompt 的软聚类最佳只做多净收益为 3.10/3.46/3.57/3.63 bp/交易日，排序由亏损领先；无聚类最佳 RankIC 则由收益领先。Prompt 确实提供了不同的选股视角，但“哪个词最好”依赖评价目标。

5.7.2 尚未确认：加入 Prompt 相对无 Prompt 的因果增量

现有四词 embedding 都是在已加入 Prompt 后生成的；尚无正文 token 位置、截断预算和 tokenizer 完全匹配的 `no-prompt body` 反事实。因此不能用这些表宣称“加入 Prompt 因果提高了多少 RankIC 或 bp”。`prompt_mean` 与目标 span 的比较是在“已经有 Prompt”的输入内选择不同池化位置；`full_mean` 跨 Prompt 高相关也只说明整段池化因子稳定，二者都不是 no-prompt 对照。严格实验必须额外生成相同行、相同 mask、相同正文可见 token 数和相同 special-token 结构的空 Prompt/无 Prompt 输入，并在每个滚动 fold 内配对 PCA 和 Ridge。完成之前，报告只写“Prompt token 提供可区分的任务视角”，不写“加入 Prompt 已被证明优于不加 Prompt”。

6. Prompt Mean、Token、全文与模型几何

6.1 RoBERTa/BGE-M3：Prompt Mean 与方向 Token

先使用旧新浪、`masked_short`、PCA128+Ridge、6+2+1 和 `next_day_return` 的历史汇总。每格是四 Prompt 的平均 RankIC；历史 `direction span` 使用盈利/收益/超额/亏损，其中“超额收益”只取“超额”。

模型	prompt_mean	历史 direction span	Prompt - Span
RoBERTa	0.05731	0.05486	+0.00245
BGE-M3	0.03313	0.03630	-0.00317

结论在模型间相反：RoBERTa 中混合“分析/股票/方向词”的整个 Prompt 平均优于只取方向词；BGE-M3 中只取方向词更好。因此 `prompt_mean` 不是天然更集中，目标 token 也不是天然更强。RoBERTa/BGE-M3 原始维度分别为 768/1,024，PCA 在各模型自身训练窗口拟合，不能把原始坐标或回归系数跨模型比较。

6.1.1 共同股票日上的 full_mean 与 Token

另一张历史表强制使用新浪 30,946 个完全共同股票日，比较的是 full_mean 与 direction span。这里必须更正旧命名：full_mean 平均 Prompt+标题+正文，不是 body_mean。

指标	RoBERTa	BGE-M3
四 Prompt full_mean 因子平均 Spearman	0.997	0.972
四 Prompt token 因子平均 Spearman	0.653	0.892
token 与对应 full_mean Top20 重合	44%	70%
masked full_mean 平均 RankIC	0.04391	0.03307
masked 历史 direction span 平均 RankIC	0.04010	0.03154

RoBERTa token 的 Prompt 间差异更大，BGE-M3 token 更接近共同方向。两种解释都可能成立：前者可能保留有用细粒度，也可能只是词形敏感；后者可能理解共同语义，也可能过度平滑。真正的 body_mean embedding 已经保存，但旧四 Prompt 研究没有完成同一新闻交集、同一 PCA 和同一滚动协议的 body_mean 回归，所以本报告不提供伪造的 body RankIC。后续公平表必须同时重跑 prompt_mean / 完整目标 span / body_mean / full_mean。

6.2 Qwen：同一 PCA32 下的三种表示

Qwen 现有“收益”实验能在 30,946 个股票日上做更干净的同 reducer 比较。下表三行都固定 masked_short + PCA32 + Ridge；prompt_mean 包含 分析/股票/收益/。 ，目标 token 只取“收益”，article_mean 只平均位于 Prompt 前的标题和正文。

表示	PCA32 RankIC	相对 article mean	成本后年化
masked article_mean	0.05680	0	8.57%
masked prompt_mean	0.05547	-0.00133	未完成同协议成本表
masked “收益” token	0.05360	-0.00319	7.37%




图 4. 三模型现有 token 与宽池化结果。RoBERTa/BGE-M3 的蓝柱实际是 full_mean，Qwen 是 article_mean；不能标成统一 body_mean，也不能当作公平模型排名。

Qwen 当前 prompt_mean 和收益 token 都没有超过 article mean。因果注意力解释了三者的信息流：article token 不看后置 Prompt；Prompt token 可以看全文并逐步看此前 Prompt token；末尾句号也只进入 prompt_mean，不进入收益 token。RoBERTa/BGE-M3 为双向编码器，前置 Prompt 会反向改变正文位置的 hidden state。这个结构差异不能通过统一 PCA 消除。

6.3 三模型四 Prompt Token 的公平比较

新实验只使用 盈利/收益/超额收益/亏损 的完整目标 span，每个模型分别在历史训练折拟合 PCA32，再以固定 Ridge 产生一级样本外因子；不做原始 768/1024/4096 维回归。二级模型 只使用同一模型自己的四个 token 因子，不混入其他模型，也不使用正文表示。best_single 由验证期 RankIC 选择，不是测试集事后最优；tree_selected 同样只按验证期从 XGBoost、LightGBM、CatBoost 中选择。

二级模型必须使用历史一级 OOS 因子，不能用一级模型样本内预测补齐。因此新浪严格二级测试 只能使用 2026：2018--2023 拟合、2024--2025 验证、2026 测试；巨潮使用 2024--2026 三个测试年，每折为 2 年拟合、1 年验证、1 年测试。巨潮表中是三个测试年的等权平均。

数据源	模型	二级方法	RankIC	RankIC IR	Top20 bp/日	多空 bp/日
巨潮	RoBERTa	最佳单 Prompt	0.033685	0.212895	87.19	85.71
巨潮	RoBERTa	四 Prompt 等权	0.029541	0.195932	84.47	82.89
巨潮	RoBERTa	验证期选择树	0.017032	0.107773	76.91	68.35
巨潮	BGE-M3	最佳单 Prompt	0.032889	0.215397	90.76	88.94
巨潮	BGE-M3	四 Prompt 等权	0.029953	0.198075	90.34	89.25
巨潮	BGE-M3	验证期选择树	0.026654	0.185772	85.66	82.47
巨潮	Qwen	最佳单 Prompt	0.052742	0.323949	91.89	95.32
巨潮	Qwen	四 Prompt 等权	0.046754	0.297340	91.52	92.32
巨潮	Qwen	验证期选择树	0.052754	0.333080	83.59	90.69
新浪	RoBERTa	最佳单 Prompt	0.008839	0.038513	-4.74	32.14
新浪	RoBERTa	四 Prompt 等权	-0.018896	-0.073211	-14.63	11.71
新浪	RoBERTa	验证期选择树	-0.011770	-0.049399	-19.27	11.52
新浪	BGE-M3	最佳单 Prompt	0.018494	0.077935	1.51	15.60
新浪	BGE-M3	四 Prompt 等权	0.032178	0.141993	6.99	30.14
新浪	BGE-M3	验证期选择树	0.016845	0.063456	-3.98	20.95
新浪	Qwen	最佳单 Prompt	0.056492	0.251086	27.82	70.95
新浪	Qwen	四 Prompt 等权	0.052728	0.223121	25.66	90.91
新浪	Qwen	验证期选择树	0.054594	0.249149	24.72	74.45

Qwen 在两个数据源上都取得最高 RankIC，证明其四个目标 token 至少形成了较强的收益排序 因子；但树模型没有稳定创造增量。巨潮 Qwen 树相对最佳单 Prompt 的 RankIC 只增加 0.000012，多空反而下降 4.62 bp/日；巨潮 RoBERTa/BGE-M3 树的 RankIC 分别下降 0.01665/0.00624。新浪 Qwen 树也低于最佳单 Prompt，而 BGE-M3 的简单等权明显高于树。

四 Prompt 因子的逐日横截面 Spearman 进一步解释了组合差异：

模型	新浪 2026	巨潮 2024--2026	当前解释
RoBERTa	0.6779	0.6919	Prompt 排序有差异，但预测较弱，不能把低相关直接解释为有用细粒度
BGE-M3	0.8771	0.8908	四词排序最接近，更偏向共同收益语义
Qwen	0.6630	0.6573	保留较多 Prompt 差异，同时得到最高收益 RankIC

这一结果支持“BGE-M3 更平滑、Qwen 更能保留细分差异”的描述，但还不满足“Qwen 已经 证明兼顾共同语义和可交易细粒度”的强结论：四 Prompt token 尚未和各模型正文做同折配对，也没有跨模型融合和日期区块 bootstrap。新浪仅有 67 个有效 RankIC 日；巨潮有 625 日。有效日期平均横截面约 53.4 只，Top20 平均约 11 只。表中 bp 未扣成本、涨跌停、容量和 卖空约束，只能用于同股票池的模型比较，不能作为可部署业绩。

7. 中性语义轴、估值与风险标签

7.1 从方向词扩展到任务词

研究先构造短/中/长收益、低/中/高估值、确定性、波动率、冲击和流动性三点轴，再形成 direction、high/low deviation、magnitude、clarity 和 neutral distance。后续又提交六个 不含高中低的中性 Prompt，用于判断“高/低”字符是否真正改变表示。

中性 Prompt 不是长度 padding。所有比较保留原始短词，并在同一模型内部使用同一 tokenizer、最大长度、mask 和正文截断合同。不同目标词 token 数不同时，不直接比较原始 token 坐标，而比较训练期标准化后的因子和样本外预测。

7.2 新 Prompt 在同一收益标签上的公平比较

这里必须先区分“单独中性 Prompt”和“三点式语义轴”：

输入	示例	是否已有同一收益标签回归	当前可报告内容
六条单独中性 Prompt	分析股票波动率、分析股票估值、分析股票风险等	没有	已有 embedding、tokenizer preflight 和相似度/完整度；不能填造 RankIC
六个三点式 direction 轴	高波动率 token - 低波动率 token；长期收益 - 短期收益	有	RoBERTa、PCA 后回归、2026 单折的三日收益 RankIC 和 Top20 多空
四方向历史 Prompt	盈利、收益、超额收益、亏损	有	RoBERTa/BGE-M3、次日收益、2018--2026 严格 6+2+1；见 4.2 节

已有监督结果不是六条单独中性 prompt，而是 18 条对齐 prompt 组成的六个三点轴。每个轴都使用 RoBERTa masked_short 目标 span，并构造 $\text{direction} = \text{high} - \text{low}$ ；期限轴对应“长期收益 - 短期收益”。所有行使用同一新闻池、同一 forward_compounded_return_3d、2018--2023 训练、2024--2025 验证、2026 测试，测试集均为 1,683 个股票日。

主口径 PCA32+Ridge 的绝对 RankIC 如下。这里展示绝对值而不是只展示 Token-Body 差值。

新语义轴	Token direction RankIC	Body direction RankIC	Token - Body	Token Top20 多空毛 bp
确定性	0.05623	-0.04496	+0.10119	+7.29
期限收益	0.04311	0.05147	-0.00837	+45.21
波动率	0.04298	-0.03323	+0.07621	+14.48
流动性	0.03324	-0.01451	+0.04775	+36.07
估值	0.02241	0.02276	-0.00035	+52.90
冲击	0.01501	0.01125	+0.00376	+6.43

最后一列是在每天至少 10 只股票时，预测最高 20% 的未来三日复合收益减去最低 20% 的未来三日复合收益，再对 2026 测试日取均值并换算为 bp。它是**未扣成本、三日窗口可能重叠的诊断量**，不能当成可交易的“日均净 bp”，也不能与第 5 节使用不同执行器的成本后组合直接比较。估值轴虽然 Top20 多空毛差最高，但 RankIC 只有 0.02241，说明尾部差异和全横截面排序不是同一个指标。

PCA 线性结果中，期限收益轴 token 比波动率轴仅高 0.00013，不能单凭这一行声称明显领先。进一步保持同一输入和标签，只替换监督/聚类方法，期限收益轴在四种方法中均高于波动率轴：

方法	期限收益轴 Token RankIC	波动率轴 Token RankIC	差值
PCA32 + Ridge	0.04311	0.04298	+0.00013
hard KMeans + Ridge	0.06059	0.04240	+0.01820
soft KMeans	0.06459	-0.01212	+0.07670
UMAP8 + HDBSCAN	-0.00881	-0.03456	+0.02575
四方法平均	0.03987	0.00967	+0.03019




图 5. 同新闻、同三日收益标签下，期限收益轴与波动率轴的 2026 样本外 RankIC。

这组结果与“收益相关 prompt 对收益更容易形成可预测分层”一致，因为期限收益轴在 4/4 方法中高于波动率轴；但证据仍有限：它只有 2026 一个测试年，PCA 主口径差距几乎为零，且确定性轴在线性结果中更高。正确表述是“收益语义在非线性分层中相对波动率更匹配三日收益”，不是“收益 prompt 已被证明普遍最好”。六条不含高中低的中性 prompt 目前只有 embedding/相似度及各自匹配标签结果，尚无同一收益标签上的公平 RankIC 横表。

因此目前最准确的横向总结是：四方向 Prompt 对次日收益已经有九年滚动证据，RoBERTa/ BGE-M3 四词平均 RankIC 为 0.05486/0.03630；新三点轴对三日收益只有 2026 单折，RankIC 从确定性的 0.05623 到冲击的 0.01501。两组标签、测试期和表示构造不同，只能分别展示，不能用 0.05623 和 0.05486 直接判断新 Prompt 优于旧 Prompt。要回答单独的分析股票波动率是否也能预测收益，仍需在同一新闻交集上运行 PCA32+Ridge，并和分析股票收益使用完全相同的 6+2+1 折与 next_day_return 标签。

7.3 估值的可检验定义

高估/低估不能由 PE 的绝对值跨股票直接比较。本项目把 PE、PB、PS 和 EV/EBITDA 的正值取对数，再减去该股票过去 252 个交易日、至少 60 日的滞后 log 中位数，得到历史相对偏离；预测标签使用下一交易日的该偏离。这控制了不同股票长期估值基准差异。

标签	Token RankIC	Body RankIC	Token-Body	2026 样本
下一日 PE log 偏离	0.0764	0.0651	+0.0113	1,119
下一日 PB log 偏离	-0.0056	0.0197	-0.0254	1,683
下一日 PS log 偏离	0.0106	-0.0069	+0.0175	1,683
下一日 EV/EBITDA log 偏离	0.0107	0.0059	+0.0048	1,274

PE 的点估计较好，但不同估值指标方向不一致，且样本只有约 1,100--1,700 个股票日。不能合并写成“估值 Prompt 已被证明有效”。

7.4 波动率和流动性的三个层次

波动率实验区分：下一交易日实现波动率绝对水平；下一日相对前一日的 $\log_{1p}$ 变化；五日后相对二十日前的波动率跳升。前者容易包含股票固有波动率差异，第二个更接近增量，第三个检验中期风险变化。

标签	Token RankIC	Body RankIC	Token-Body	2026 样本
下一日实现波动率水平	0.0553	0.0550	+0.0003	1,671
下一日实现波动率 log 变化	-0.0236	-0.0085	-0.0151	1,671
五日/二十日波动率跳升	0.0310	0.0253	+0.0057	1,674

流动性使用一分钟买卖价差聚合。下一日价差水平 token/body RankIC 为 0.1881/0.2151；价差 log 变化为 -0.0092/-0.0325。高水平预测强，但可能主要反映稳定的个股流动性差异；变化预测较弱。因此下一步应增加逐股/行业残差化和滞后标签基线。

8. 巨潮公告扩展

8.1 合并面板 pooled 结果

巨潮 pooled embedding 使用 903,665 条合并公告记录、RoBERTa/BGE-M3、short 和 masked-short，共 72 个一级样本外回归配置，测试覆盖 2018--2026。这里的输入面板是 2010--2017 全部公告与 2018--2026 重点公告的合并，不是全时期全部公告。由于 6+2+1 滚动窗口跨过 2018 年筛选断点，早期训练集和后期测试集的公告类型分布不同；跨年为正 说明信号在该实际数据合同下可重复，不等于对“全公告口径”稳定。

配置	平均 RankIC	正年份
RoBERTa masked full_mean SmallMLP PCA128	0.01764	9/9
RoBERTa short body_mean SmallMLP raw	0.01665	7/9
BGE-M3 masked concat Huber raw	0.01415	9/9
BGE-M3 masked full_mean Huber raw	0.01369	9/9

这些结果说明公告 pooled 表示存在较弱但跨年为正的信号，也说明不同模型的最优预测头 不同。它们不是四 Prompt token 的公平比较，不能拿来回答 token 是否优于正文。

8.2 Qwen 巨潮结果

Qwen 巨潮 3+1+1 辅助滚动的 masked-short PCA32 Huber SGD RankIC 为 0.02732，5/5 年方向一致；严格 2026 点估计为 0.02247，但 95% 区间 [-0.00181, 0.05117] 跨 0，且 plain 的点估计略高于 masked-short。当前只能称为弱而可重复的线性信号。

8.3 横截面和数据源边界

巨潮合并面板有 90 万余条公告记录，却只覆盖同一批 816 只股票，且公告范围从全部公告 切换为重点公告；新浪股票更广但来源、长度和 年份结构不同。两数据源的模型结果不能按原始 RankIC 直接归因于“新闻优于公告”或反之。公平比较需要同一股票日、同一目标、相同训练历史和相同可评分横截面。

9. 排序、收益与风险解释

9.1 IC 与组合收益不是同一指标

RankIC 使用每天整个可评分横截面的排序；Top20% 组合只看尾部，并受持仓平滑、换手、成本和收益偏度影响。因此“超额收益”有最高软聚类 RankIC，而“亏损”有最高成本后只做多，并不矛盾。报告必须同时给出排序和经济结果。

9.2 Token 的价值可能集中在尾部

旧比较中，RoBERTa token 与 full_mean Top20 重合只有约 44%，BGE-M3 约 70%。RoBERTa 盈利、收益、亏损 token 相对对应 full_mean 的多空收益增量曾为正，而超额收益是反例。这提示 token 可能主要改变尾部选股，而不是整体 RankIC；但该机制需要在新公平样本上复核。

9.3 成本和卖空限制

四方向最佳只做多年化 8.30%、Sharpe 0.595，最大回撤仍为 -22.87%。最佳理论多空 年化 4.64%、Sharpe 0.515，且独立空头配置成本后均未形成正 Sharpe。没有券源与借券费时，应把低分端理解为风险规避或降低权重候选，而不是直接做空策略。

9.4 需要补充的风险归因

下一步的经济评价应在同一股票日加入市场和行业调整收益、规模、动量、短期反转、beta、历史波动率、流动性、换手和新闻数量。只有“传统因子”“新闻因子”“传统加新闻”在完全 同折下比较，才能判断文本是否提供独立增量。

10. PCA、聚类与模型融合

10.1 为什么主结果只做 PCA 后回归

三模型原始维度差异大，且高维样本量比例不同。主口径固定训练期 randomized PCA32 后 StandardScaler 和 Ridge alpha 100，不再运行原始维回归。这使跨模型统一成为“同算法、同维数、同历史窗口和同参数”，而不是错误地共享同一个 PCA 基底。

10.2 聚类原理与本项目实现

聚类不是独立重复一份无监督图，而是在训练期 PCA 表示上检验离散或非线性语义状态能否 对未来收益产生监督增量。四类方法使用相同 fold，所有变换只在训练期拟合。

方法	原理	当前实现
硬 MiniBatchKMeans	最小化样本到最近质心的平方距离，得到离散状态	PCA32 后 k=6，one-hot/质心距离与 PCA 特征进入 Ridge；历史 sweep k=2/4/6/8/12
软 KMeans	用距离 softmax 替代硬边界，以 membership 加权簇收益	temperature=0.5；训练期簇收益向全局均值 shrinkage=500；测试冻结
UMAP+HDBSCAN	UMAP 保留局部近邻，HDBSCAN 按密度发现非球形簇并允许噪声	PCA -> UMAP8 (cosine, neighbors 30, min_dist 0.1) -> HDBSCAN (50/10) -> Ridge
GMM	PCA 空间的多高斯混合，以后验概率表示重叠簇	Qwen 结构复核使用 k=3/5/8；不作为当前主收益选择器

软 KMeans 的训练期簇收益为 $\mu_k = (\sum(y_i \text{ in } k) + 500 * \text{global_mean}) / (n_k + 500)$ ，样本分数为各簇 μ_k 按距离 membership 的加权和。验证和测试收益不参与 μ_k 。UMAP/HDBSCAN 的验证测试标签通过 训练期 transform/approximate prediction 获得，不能在全样本 UMAP 图上回填收益。

ARI 检查不同 seed/年份的分簇一致性，silhouette 检查簇内/簇间几何，noise share 检查 HDBSCAN 是否退化；它们只用于描述结构，不能用于选择收益模型。有效性只看与同一 PCA+Ridge 配对的 OOS RankIC、组合和跨年稳定性。

10.3 聚类的正面和负面证据

硬 KMeans：结构变化没有转化为整体收益增量

硬 KMeans 在四方向 16 个严格配对中平均降低 RankIC 0.00026，仅 6/16 胜。更重要的是，从底层预测按原执行器重算 Top20% 多头后，线性 Ridge 平均为 4.77 净 bp/信号日，硬聚类为 4.28 bp，平均少 0.49 bp，仅 7/16 胜。

Prompt	线性净 bp/信号日	硬聚类净 bp/信号日	硬-线性	硬聚类胜出
盈利	6.03	6.99	+0.96	4/4
收益	6.72	6.38	-0.34	2/4
超额收益	1.88	1.05	-0.83	1/4
亏损	4.46	2.68	-1.77	0/4
全部	4.77	4.28	-0.49	7/16




图 6. 相同四 Prompt、模型和 mask 配对下的 Top20% 多头净 bp；成本已扣，但组合平均仅 2.80 只。

两种方法都覆盖 1,991 个信号日，平均只持有 2.80 只股票；日均交易成本分别高达 14.45/14.45 bp，正收益日比例仅 45.15%/45.16%。正净收益由少数较大上涨日驱动，且组合 高度集中。盈利 Prompt 是完整正例，亏损 Prompt 是完整反例；所以硬簇可保留为结构诊断，不能作为默认收益增强器。

软 KMeans：当前优势主要在持仓平滑和尾部

软聚类最高 RankIC 0.04439，仍低于无聚类 Ridge 0.06044。它的固定成本多头却能取得 3.10--3.63 净 bp/交易日，原因是距离 membership 和训练期簇收益把离散簇变成连续分数，同时 $\gamma=0.1$ 将换手压到约 5.5%、成本压到约 0.55 bp/日。名义持仓约 94 只，但权重有效持仓约 14.4 只；两者都不是当日 Top20% 的数量。因此软聚类组合更平滑、更分散，但现有文件没有“同一慢调仓执行器下软簇 vs 线性 Ridge”的配对基线，不能把全部差额判给聚类算法。

UMAP+HDBSCAN：局部正例，但未计成本

对 BGE-M3 masked “亏损” token 的底层预测重新按 runner 规则聚合：先取股票日均值，只保留至少 10 只股票的日期，取首尾 $\text{ceil}(20\%)$ ，再等权平均九个测试年的日均值。

方法	多头 bp/信号日	低分组 bp/信号日	多空 bp/信号日	每腿平均持仓	有效信号日/年	成本
PCA+Ridge	+0.13	-14.83	+14.96	4.89	132.9	未计
UMAP+HDBSCAN+Ridge	+5.18	-14.54	+19.72	4.89	132.9	未计

密度聚类将多空提高 4.76 bp，且两者都是 8/9 年多空为正；但增量主要来自多头，2021 年仍为负，平均每腿不足 5 只，并且没有交易成本。它只完成了一个模型、一个 Prompt，不能外推到四词或部署收益。旧总报告的 1.50/6.17 和 15.26/20.35 bp 来自早期汇总；本报告改用 predictions.parquet 按当前 runner 函数重算的 0.13/5.18 和 14.96/19.72 bp，避免混用聚合版本。

2026 单折的六语义轴中，PCA+Ridge 和硬 KMeans 的平均 token-body delta 为 +0.03670/+0.03344，软 KMeans 和 UMAP+HDBSCAN 为 -0.01451/-0.00881。它们预测的是三日收益且只有一个测试年，只能继续作为“聚类增量依赖任务”的补充证据。

10.4 多因子融合的严格方案

公平比较目前已生成 12 个完全样本外基础 token 因子：3 模型 $\times$ 4 Prompt。每个模型的四 token 已分别完成等权、最佳单 Prompt 和验证期选择树模型；这不是三模型融合。尚未完成的部分是 12 个 body 因子、token/body 配对、单 Prompt 三模型融合以及全部跨模型 late fusion。后续输入先逐日横截面标准化，再比较等权、Ridge、ElasticNet 和 HistGradientBoosting；二级权重只能使用历史 OOS/验证数据，测试年冻结。

10.5 当前不能写出的结论

- 不能因 RoBERTa Prompt 间距离大就写“RoBERTa 不理解语义”；
- 不能因 BGE-M3 token 相关高就写“BGE-M3 理解更准确”；
- 不能因 Qwen 局部软聚类更强就写“Qwen token 已超过正文”；
- 不能把已完成的新浪 35,576 和巨潮 254,544 条 embedding 交集直接当作树模型的股票日样本量；
- 不能把已完成的三模型 token 比较写成 token/body 或跨模型融合已经完成；
- 不能用一次 2026 单折的估值/风险结果替代 6+2+1 跨年验证。

11. 综合判断与下一阶段

11.1 当前证据等级

结论	证据	当前判断
文本 embedding 含收益排序信息	新浪多个配置 9/9 年正；巨潮 pooled 多个配置跨年正	支持弱文本因子
Prompt token 提供可区分任务视角	四方向持仓/bp、因子相关、不同 span 排名	支持；加入 Prompt 的因果增量尚未识别
Token 普遍优于宽池化	两模型历史 token 略低于 full_mean；Qwen token 也低于 article_mean	不支持
RoBERTa 与 BGE 的 Prompt 几何不同	因子相关 0.653 对 0.892，full_mean 相关均很高	支持结构差异，不等于理解优劣
聚类稳定提高收益预测	硬聚类净 bp 平均 -0.49；软簇 $\gamma=1$ 净 -0.55；UMAP 只有单 Prompt 无成本正例	当前不支持
收益语义比波动率语义更匹配三日收益	同一 2026 折中期限收益轴 4/4 方法高于波动率轴；PCA 仅高 0.00013	与假设一致，但只是单年探索证据
估值 Prompt 预测高估/低估	PE 有正点估计，PB/PS/EV 分化，单年小样本	探索性证据
波动率 Prompt 预测未来风险	水平略正，log 增量更弱	仅支持水平信息，增量未验证

结论	证据	当前判断
Qwen 四 Prompt token 同时保留差异并有较强收益排序	新浪/巨潮因子相关 0.663/0.657; RankIC 0.05649/0.05274, 均领先	支持 token 层描述; 未完成正文和跨模型融合, 不能升级为完整理解结论

11.2 当前可保留的基线

1. 新浪 next-day: RoBERTa masked 分析股票收益 prompt_mean PCA/Ridge 主基线。
2. 新浪 event-3: RoBERTa/BGE-M3 masked “收益” span 各自 PCA 后拼接 Ridge。
3. 方向 Prompt 机制: 四词目标 span token 与真正 body_mean 的严格配对。
4. 巨潮公告: 现有 pooled 72 配置只作为公告全文基线; 三模型 token 比较单独报告。
5. 非线性: 只在 PCA32 因子或完全 OOS 预测层运行 HistGradientBoosting, 不再扩展高维树网格。

11.3 下一阶段优先级

1. 在已冻结的新浪 35,576 条、巨潮 254,544 条交集上补齐同折 body_mean/article_mean, 完成 token/body 配对。
2. 对现有 PCA32 token OOS 因子补做日期区块 bootstrap、逐年增量、Top20 重合和标准因子残差化。
3. 在基础 OOS 因子上做 Ridge、ElasticNet 和 HistGradientBoosting 跨模型 late fusion; 固定树模型不再扩网格。
4. 在相同股票日上让线性 Ridge、硬簇和软簇共用 $\gamma=0.1/1.0$ 与 hold/close 规则, 拆出算法净增量。
5. 将估值标签扩展为行业相对和横截面分位; 将波动率/价差同时报告水平、变化和滞后基线增量。
6. 把文本因子与量价、beta、行业、规模、动量、反转和流动性因子放入完全共同股票日比较。
7. 只有达到至少 6/9 年方向一致且区块 bootstrap 区间不跨 0, 才升级为主结论。

11.4 主线一：证明不同 Prompt 真的产生不同因子

这条主线的目标不是证明某个词的 embedding 距离更大, 而是证明在同一篇新闻上替换目标 短语, 会产生可重复、样本外、具有经济含义的不同横截面排序。历史表中 RoBERTa/BGE-M3 目标 token 的跨 Prompt Spearman 约为 **0.653/0.892**; 新公平 token 因子在新浪为 **0.678/0.877**, 在巨潮为 **0.692/0.891**, 方向一致。Qwen 新结果为新浪 **0.663**、巨潮 **0.657**, 并在两个数据源上取得最高 RankIC。这说明模型确实产生不同的 Prompt 排序, 但还不能单独说明“理解”或加入 Prompt 的因果效应。

验证按三层递进:

层次	要回答的问题	固定条件	主要验收
表示层	替换 Prompt 是否改变目标 span, 而不是只改变 token 数?	同模型、同 tokenizer、同 mask、同正文截断、同 PCA32 训练窗口	centered cosine、标准化 L2、CKA; 同日因子 Spearman 与 Top20 重合显著低于 1
预测层	不同 Prompt 是否对应不同的未来标签信息?	严格 6 年训练 + 2 年验证 + 1 年测试; PCA32 后 Ridge; 所有变换只在历史训练折拟合	配对 RankIC/IR、逐年 delta、日期区块 bootstrap; 至少 6/9 个测试年方向一致
经济层	差异是否能转化为可执行的选股增量?	同股票日、同 Top20 规则、同持仓平滑、同成本和容量约束	日均 bp、持仓数、换手、成本后年化/Sharpe、行业和规模暴露; 加入传统因子残差后仍有增量

公平对照必须同时包含三类控制:

1. **位置/长度控制**: 目标词保留在相同 Prompt 槽位, 使用同 tokenizer 和同最大长度; 不使用 “公司” “信息” 等无关 padding。六条中性 Prompt 的差异应报告实际 token budget, 不把字符等长 当成 token 等长。
2. **无 Prompt 控制**: 在相同正文上比较 no-prompt、neutral Prompt 和目标 Prompt, 估计 Prompt 本身对正文 hidden state 的影响。RoBERTa/BGE-M3 前置 Prompt 会改变正文状态, Qwen 的 article_mean 不会看见后置 Prompt, 因此三模型不能只看 pooled 均值下结论。
3. **语义安慰剂**: 加入同长度、同位置但与标签无关的中文短语, 或在训练期随机置换目标词标签。若安慰剂也得到同等增量, 应判定为槽位/规模伪影, 而非 Prompt 因子。

“不同因子”的最低证据链是: 目标 span 的 centered cosine 不完全相同; 单 Prompt 的 OOS 预测相关不完全相同; 四 Prompt 等权或正则化融合在冻结测试年超过最佳单 Prompt; 并且增量在传统市场、行业、规模、动量、反转、beta、历史波动率、流动性和新闻数量残差化后仍存在。如果只有几何差异而没有样本外或组合增量, 只能写“表示被区分”, 不能写“形成独立因子”。当前新浪 BGE-M3 等权超过验证期最佳单 Prompt, 但其他模型/数据源不一致; 树模型也没有 稳定增量, 因此证据停留在“相关但不同的 OOS 因子”, 尚未达到独立可交易因子的验收线。

11.5 三模型相关性应该如何理解

三模型的相关性要分成“表示几何相关”和“预测信息相关”。不能直接比较 RoBERTa 的 768 维、BGE-M3 的 1024 维和 Qwen 的 4096 维原始坐标，也不能把低 cosine 直接解释为模型不理解。统一口径是各模型在每个滚动训练折分别做 PCA32 + StandardScaler，再比较标准化后的统计量。

模型	结构事实	当前可观察结果	后续解释重点
RoBERTa	双向 encoder, Prompt 在正文前, hidden size 768	新 token 因子相关: 新浪 0.678、巨潮 0.692; 树模型弱于最佳单 Prompt	区分度较高但预测较弱, 差异可能包含词面敏感
BGE-M3	双向多语 encoder, Prompt 在正文前, hidden size 1024	新 token 因子相关: 新浪 0.877、巨潮 0.891; 三模型中最高	共享收益语义最强, 但固定树没有利用出额外增量
Qwen3-Embedding-8B	因果 embedding, Prompt 在文章后, hidden size 4096	新 token 因子相关: 新浪 0.663、巨潮 0.657; 两个数据源 RankIC 最高	article_mean 与后置 Prompt 信息流分离; 需补四 Prompt 正文配对和跨模型融合

后续每个模型×Prompt×表示输出四类跨模型证据：

- **几何**：逐新闻 raw/centered cosine、标准化 L2、linear CKA；只在各自标准化空间比较。
- **因子**：逐日横截面 z-score 后的因子 Spearman、RankIC IR、Top20 重合和持仓重合。
- **残差**：用某一模型的 OOS 预测解释另一模型预测，计算残差相关和增量 R²；避免把共同市场 方向误判为互补。
- **融合**：等权、Ridge、ElasticNet 和 HistGradientBoosting 只在验证期选权重，测试年冻结。

“模型互补”的判定必须是预测性而非审美性的：融合至少在 6/9 年超过最佳单模型，日期区块 bootstrap 的配对增量区间不跨 0，同时 Top20 重合下降伴随成本后 bp 或风险预测改善。若 Qwen 与 BGE-M3 高相似但融合没有增量，结论应改为“表示平滑、但没有可交易的细粒度信息”；若 RoBERTa 相关较低但融合有效，则说明低相关可能代表可利用的分解，而不是模型质量较差。

11.6 主线二：Regime、全股票与宏观新闻扩展

Regime 不能只用“波动率”一个词或单一水平标签。要把状态变量定义为可解释的未来水平、变化和冲击，并先做逐股/行业残差化，区分个股固有差异与新闻带来的增量。

方向	目标定义	关键控制与数据	首要检验
波动率	下一日实现波动率水平；下一日 log1p 变化；5/20 日跳升；尾部/jump 事件	1 分钟 OHLCV、成交量，至少保留前一日和未来窗口；股票固定效应、行业和市场波动率	分析股票风险/波动率 token 是否预测未来风险增量，而非只识别高波动股票
流动性	下一日买卖价差水平；价差 log 变化；成交量/换手冲击	1 分钟 bid/ask 或成交价重构 spread、日成交额、流通市值、停牌/涨跌停	水平信号与变化信号分开；报告成本、容量和有效持仓，不只看 RankIC
全股票横截面	每个交易日对所有合格股票打分，新闻缺失不静默删除	上市/退市、停牌、复权、行业、规模、新闻覆盖和缺失指示变量	覆盖率、有效股票数、持仓数、换手、行业/规模暴露；与新闻子样本并列比较
宏观/指数新闻	CSI 300/500/1000、上证综指、深证成指、创业板指及行业指数的新闻聚合	指数成分有效期、指数 OHLCV、指数新闻时间戳、来源和正文 hash	下一日指数收益、波动率、成交额、涨跌家数/breadth；检验市场级新闻因子

波动率和流动性应至少设置三个标签版本：绝对水平、相对前一日的 log 变化、未来窗口的 跳升/冲击。水平标签可以有很高的 RankIC，却只是股票长期特征；变化标签更接近 Regime 转换。模型评价同时给 RankIC、IR、尾部命中、风险校准、成本后 bp、换手和容量。对高频数据覆盖不足的早期新闻，可以按可用区间砍掉新闻，但必须重新冻结训练/验证/测试年份和样本量， 不能把不同覆盖期的结果拼成一个时间序列。

推广到全股票时，新闻缺失必须显式编码为“无新闻/缺失”，不能把没有新闻的股票从横截面 删除，否则模型只在新闻覆盖最好的股票上有效。主结果应提供三组对照：新闻股票池、全市场 含缺失指示、全市场只在有新闻股票上评分；并报告每天可评分股票数、有效持仓、行业集中度、规模暴露和换手。这样才能判断信号是可扩展的横截面因子，还是少数高覆盖股票的选择效应。

宏观新闻采用层级结构，不把一条指数新闻复制给所有成分股。第一层把指数/市场新闻按等权、 市值权重、新闻数量、稳健中位数和最大冲击聚合，预测指数收益、波动率和 breadth；第二层用 个股新闻对该市场因子残差化，再预测个股超额收益；第三层加入市场波动率、流动性和成交量 Regime 的交互项。候选来源包括新浪本地抓取、巨潮公告、指数成分与行业映射；东方财富、雪球 只作为投资者情绪的补充实验，遵守可见页面、限速和不绕过登录/CAPTCHA 的边界。

推荐执行顺序如下：

1. 在已完成的三模型四 Prompt token 共同样本上补生成 body/no-prompt 的同折 OOS 因子。
2. 在同一标签上完成跨模型残差、日期区块 bootstrap 和冻结 late fusion，进一步回答“是否形成独立因子”。
3. 将波动率和价差扩展到水平、变化、跳升三类，完成逐股/行业残差化和成本容量审计。

4. 建立全股票横截面面板，显式处理无新闻股票、退市和停牌，再比较覆盖与经济结果。
5. 爬取和整理指数/行业新闻，先做市场级预测，再做个股残差层和 Regime 交互。
6. 最后才把 Prompt 因子、模型融合和市场状态交互放入统一组合；所有权重只用历史验证期选择。

11.7 当前资产完整性

六个中性 masked-short Prompt 的 embedding 完整性如下。RoBERTa 新浪完整；巨潮缺一个分片；BGE-M3 剩余任务已主动取消并保留完成产物，因此只能在已完成分片交集探索。




图 7. 中性六 Prompt embedding 分片完成度。未完成 BGE-M3 不能冒充全量结果。

12. 研究边界

- 新浪与巨潮虽然都覆盖 2010--2026，但年度分布、股票覆盖、文本类型和标签可用率不同。
- 旧新浪 75,894 条、全量新浪 796,553 条和巨潮 903,665 条的 `row_index` 不可混用。
- 2026 新浪数据量异常高，任何随机切分都会受到来源与时间漂移影响。
- 巨潮当前合并面板只覆盖 816 只股票，且 2010--2017 为全部公告、2018--2026 为重点公告；不代表无偏全 A 股公告历史，也不能把 `full` 文件名解释为全时期全公告。
- RoBERTa/BGE-M3 是双向编码器，Qwen 是因果模型；Prompt 位置影响机制不同。
- Qwen 已完成四 Prompt token 因子比较，但 token/body 对照仍只有单一“收益”Prompt，不能代表四 Prompt 平均正文增量。
- 六条不含高中低的中性 Prompt 尚无同一收益标签监督横表；新 Prompt 收益横比来自三点 direction 轴，不能写成单一分析股票波动率 token 的结果。
- 估值、波动率和价差结果目前主要来自 2026 单折和约 1,100--1,700 个股票日。
- 聚类超参数、PCA 和 scaler 必须在训练期拟合；ARI/silhouette 不能选择收益模型。
- 成本回测未包含容量、冲击、涨跌停、融资、借券费和券源召回。
- `simple_states ErrorCode=1002` 的结果不是正式成本后策略证据。
- 本报告描述预测关系和表示结构，不提供因果解释，也不构成投资建议。

附录 A：Prompt 与表示合同

实验族	Prompt	变体	目标 span	正文表示
四方向	分析股票盈利	masked-short	盈利	body_mean/article_mean
四方向	分析股票收益	masked-short	收益	body_mean/article_mean
四方向	分析股票超额收益	masked-short	超额收益	body_mean/article_mean
四方向	分析股票亏损	masked-short	亏损	body_mean/article_mean
中性估值	分析股票估值	masked-short	估值	body_mean
中性确定性	分析股票确定性	masked-short	确定性	body_mean
中性波动率	分析股票波动率	masked-short	波动率	body_mean
中性冲击	分析股票冲击	masked-short	冲击	body_mean
中性流动性	分析股票流动性	masked-short	流动性	body_mean
中性风险	分析股票风险	masked-short	风险	body_mean

上表是目标表示合同，不是已完成结果清单。四方向历史宽池化回归实际使用 full_mean；真正 body_mean 只完成 embedding 保存、尚无同口径 RankIC。历史“超额收益”word-span 只取“超额”，新三模型公平合同才取完整“超额收益”。

附录 B：主要事实来源

事实	可追溯产物
新浪两种采集流程、默认并发和微探针	scripts/run_sina_auto_pipeline.py、scripts/select_sina_historical_seeds_browser.py、data/interim/sina_probe.json
巨潮 2010--2017 股票年和原始记录	reports/cninfo_historical_collection_audit.json、reports/cninfo_historical_cleaning_audit.json
东方财富/雪球可见页面边界和批次	scripts/collect_browser_visible.py、scripts/run_100_stock_collection.py
模型 ID、维度、最大长度和表示合同	references/data_sources_and_models.md、embedding manifest/preflight
全量面板行数、日期、股票数、标签覆盖	facts.json；scripts/audit_research_handoff.py；相应 Parquet schema
四方向 Prompt、mask、成本和聚类结果	工作区 REPORT_ALL_RESULTS.md，SHA256 23ade165...e4ff
short/masked-short 线性 RankIC 配对	audits/prompt_mask/rankic_pairs.csv、summary.json；生成器 scripts/audit_prompt_mask_rankic.py
Prompt mean、方向 span 与 Qwen 三表示 RankIC	audits/prompt_representations/；生成器 scripts/audit_prompt_representation_rankic.py
四方向与新语义轴的收益回归展示	audits/prompt_return_regressions/；生成器 scripts/audit_prompt_return_regression_display.py
三模型各自四 Prompt token 因子与树模型	audits/per_model_prompt_token_tree/summary.csv；底层产物 per_model_prompt_token_tree_v1/
估值、波动率、价差配对结果	reports/aligned_extended_regression/token_body_selected.csv
新语义轴聚类配对	reports/aligned_factor_clusters/token_minus_body_delta.csv
中性 embedding 完成度	docs/status_snapshot_2026-08-26.json 和 embedding shard COMPLETED
论文书目信息和原文校验	references/papers_manifest.tsv、references/paper_to_experiment_map.md

附录 C：结果解释的优先级

1. 冻结输入、严格滚动、跨年完成且有明确标签的样本外结果；
2. 同新闻、同标签、同历史窗口的配对结果；
3. 单年严格测试和小样本语义匹配探索；
4. embedding 几何、聚类质量和可视化；
5. 尚未运行完成的设计、token/body 和跨模型融合研究假设。

低优先级证据不能覆盖高优先级证据。尤其不能用 cosine 解释替代 token/body 的样本外 预测，也不能用单个最优组合覆盖所有其他 Prompt 和模型的负结果。

附录 F：指标和方法速查

名称	定义	本报告解释
日均 RankIC	每日预测与目标横截面的 Spearman 相关再平均	首要排序指标，不年化
RankIC IR	日度 RankIC 均值除以标准差	衡量稳定性，需同时报告日期数
正年份数	测试年份中 RankIC 大于 0 的年份数	方向稳定性，不代表统计显著
OOS R ²	相对历史均值预测误差的改善	可为负而 RankIC 为正
Top20 重合	token 与正文最高 20% 股票集合的交集比例	描述尾部选择相似度
centered cosine	去除训练期 Prompt 均值后的余弦	减少全局 Prompt 偏差
线性 CKA	两组表示样本几何的一致性	可跨不同原始维度描述，不共享坐标
PCA32 Ridge	训练期 PCA32、标准化、固定 alpha 100	三模型公平比较主基线
hard KMeans	PCA 后簇 one-hot 与连续特征进入 Ridge	聚类增强，必须配对同 PCA Ridge
soft KMeans	距离软分配加训练期簇收益收缩	连续分层，不使用测试收益定义簇分数
UMAP+HDBSCAN	训练期 PCA/UMAP/密度簇后进入 Ridge	稳健性复核，不以 silhouette 选收益模型
GMM	PCA 空间高斯混合的后验软 membership	Qwen 结构复核，当前不作为主收益选择器
净年化/Sharpe	扣固定交易成本后的组合收益统计	仍未包含容量、涨跌停和借券约束

参考文献

- Chen, Y., Kelly, B., and Xiu, D. Expected Returns and Large Language Models. 2024.
- Yang, Z. Investor Sentiment in the Chinese Stock Market. PhD thesis, 2023.
- Jiang, F., Liu, Y., Meng, L., and Zhang, H. Deep learning, textual sentiment, and financial market. 2024.
- Zhang, C. Deep learning based Chinese text sentiment mining and stock market correlation research. 2022.
- Wang, X. Topic Modeling in Finance: A Review of Methods, Applications, and Challenges. 2026.